食料品小売業者の売上予測

-時系列予測モデル-

2022年 10月18日

NeuroDiveFukuoka

小林稔征

自己紹介

氏名	小林　稔征
居住地	福岡市
目標	Pythonを使用して、 世の中の課題解決が 出来るような仕事に就く
大学	システム生物学 階層クラスタリング
職歴	Web広告運用 システム営業
経験	ふくおかAI・DXスクールでチーム開発 (2022.1)

成果物タイトル：食料品小売業者の売上予測

-時系列予測モデル-

Kaggle:	Store Sales - Time Series Forecasting https://www.kaggle.com/competitions/store-sales-time-series-forecasting
業務課題	商品を適切なタイミングでお客様に十分に提供することで以下の課題を解決する。 ①過剰在庫削減。（２０２０年度日本の食品小売業の食品ロス量は６０万トン） ②売上向上。（商品の品切れを防ぎ、顧客満足度を向上する）
タスク内容	食料品小売店の訓練データ（売上値他）、石油データ、祝日イベントデータ、取引データ、店舗データを用いて、特定日時、特定店舗、特定製品の売上を予測する。
制作情報	使用言語・環境：Python・JupyterNotebook 制作期間：2か月

AIモデル企画の構成要素

1 業務課題

食料品小売店における商品需要を予測する

2 課題のためにAIで何を行うか

売上の予測モデルを学習、回帰問題

3 データ

テーブルデータ

ファイル数
5種類
・train.csv
・oil.csv
・holidays_event.csv
・transactions.csv
・stores.csv

説明変数
１９種類
目的変数
１種類

4 使用するAI技術

機械学習：教師あり学習
勾配ブースティング
３種類
・Lightgbm
・Xgboost
・Catboost

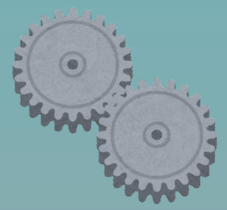

5 必要な前処理

・データマージ（データ結合）
・質的データを数値データに変換
・欠損値・異常値処理
・特徴量の追加
・次元削減

6 評価指標

ビジネス
・売上向上
・過剰在庫削減

AIモデルの評価
・RMSE(誤差:値が0に近いほど良い精度)

7 必要なタスク

・データセットをFix
・運用フローの設計
・各手法での精度評価、パラメータ調整
・どのアプローチが良さそうか。
・更なるパラメータ調整

8 モデル運用フロー

実務の運用フロー
・AIモデルをどこで使用するか（１５日間）

9 理想のアウトプット（目的変数）

売上金額（予測）

取り組みの方向性

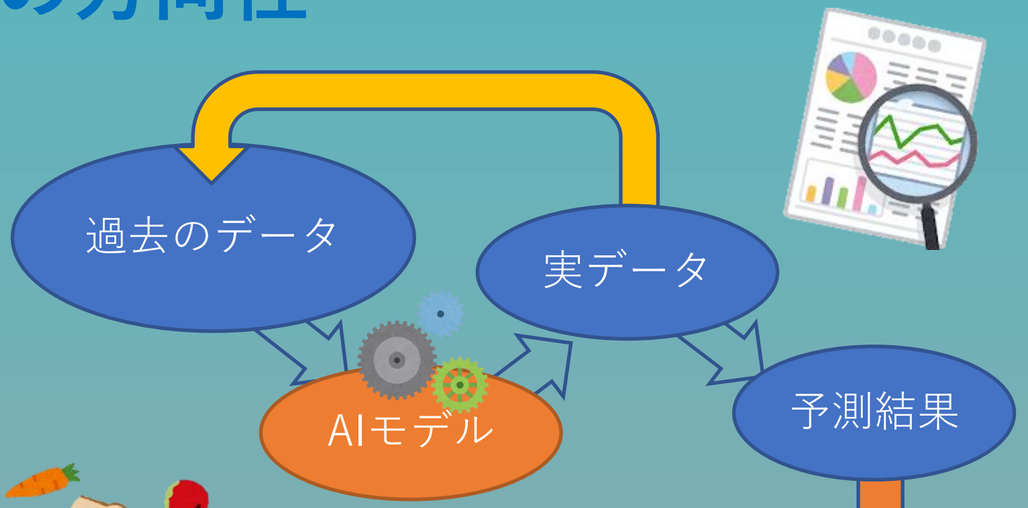

過剰在庫
→食品ロス

最適な需要と供給

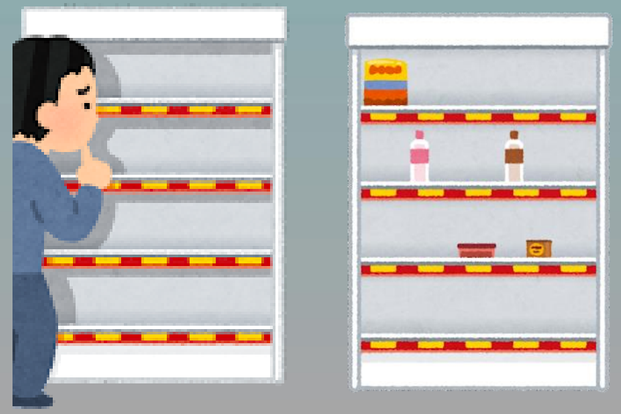

在庫不足
→売上減少、顧客満足度の低下

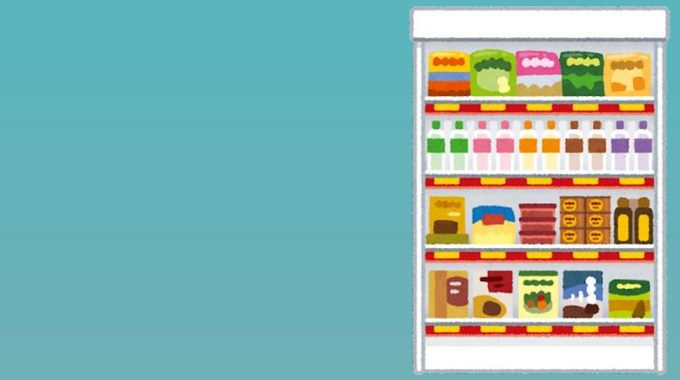

売上向上と過剰在庫削減

予測結果をもとに食品の買い付け

取り組み

1. データ
2. EDA
3. モデル開発
4. 施策改善と精度

データ

分析対象企業

企業名：CorporaciónFavorita
・エクアドルの大手食料品小売業者

・データ中の店舗数は54、製品種別は33である。時間軸は2013-01-01から始まり、2017-08-15で終了

データ

テーブルデータ

訓練データ

- 日付
- 識別番号
- 店舗番号
- 製品種別
- 売上
- 宣伝製品数

石油データ

- 日付
- WTI原油先物価格

休祝日_イベントデータ

- 日付
- 祝日種類
- 適合範囲
- 適合範囲名
- 説明
- 政府都合の休日

取引データ

- 日付
- 店舗番号
- 領収書発行数

店データ

- 店舗種別
- 店舗番号
- 州
- クラスタ

EDA

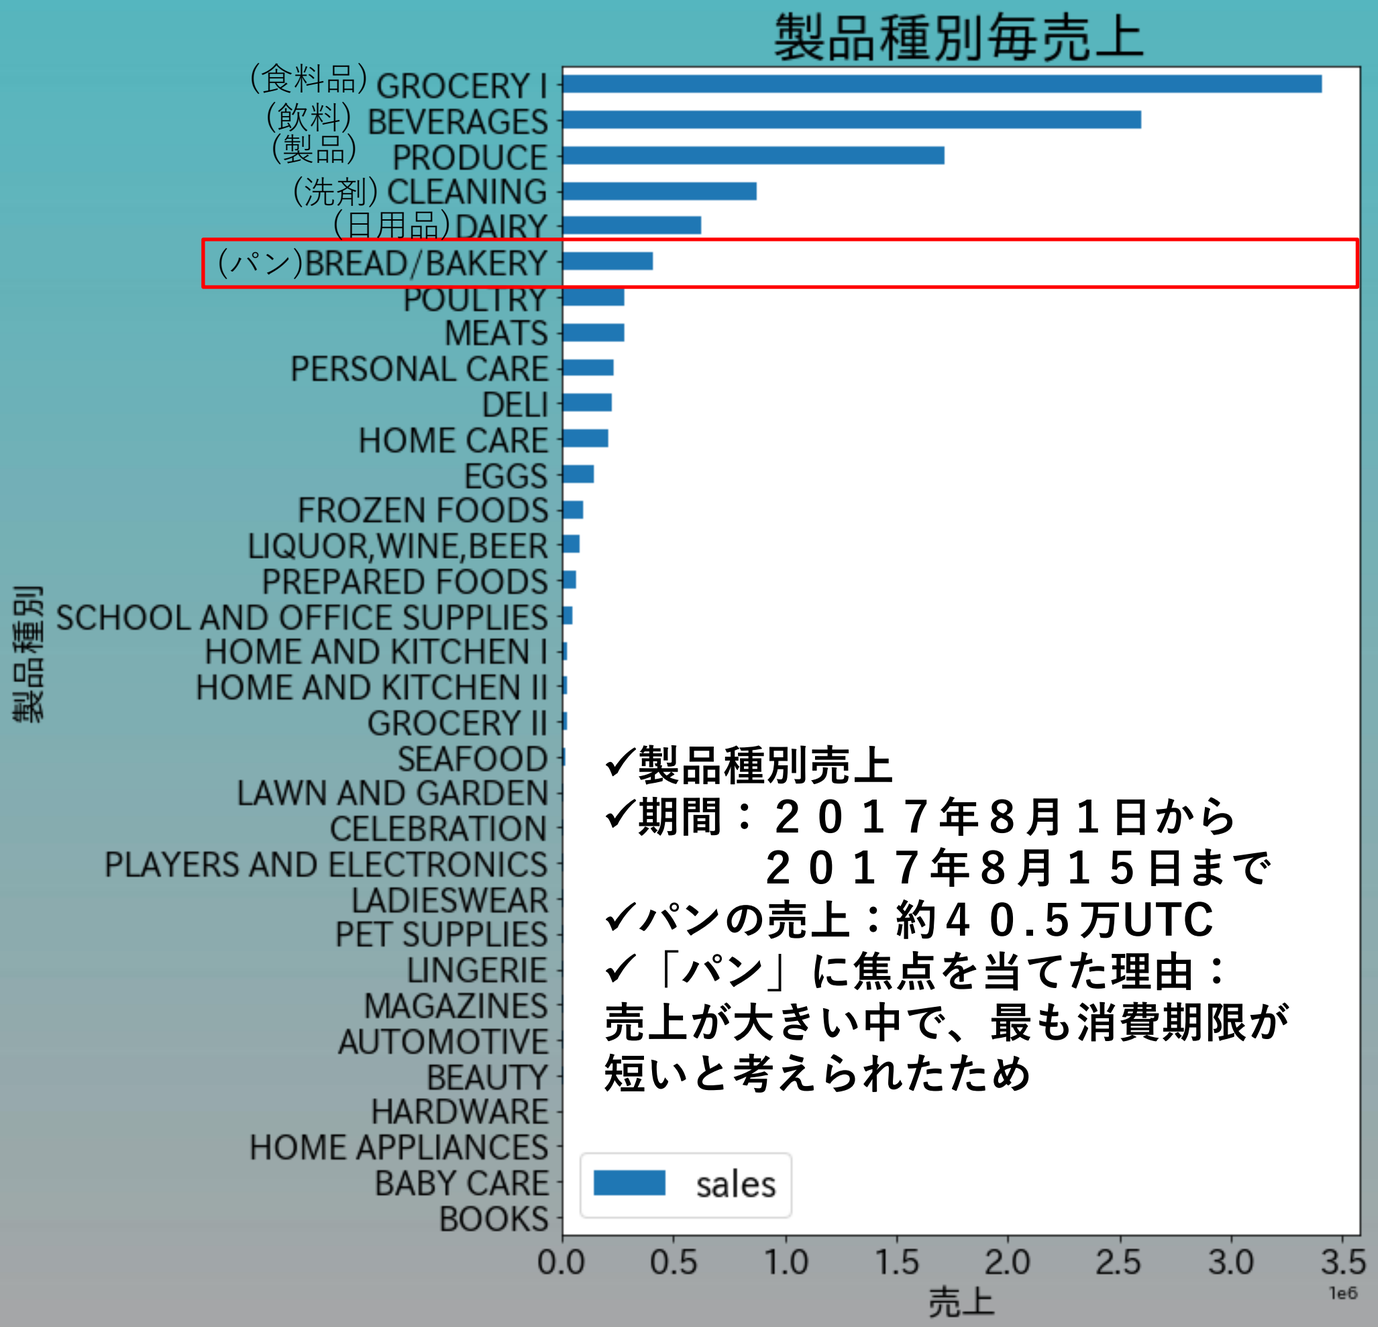
製品種別毎売上
(食料品) GROCERY I
(飲料) BEVERAGES
(製品) PRODUCE
(洗剤) CLEANING
(日用品) DAIRY
(パン)BREAD/BAKERY
POULTRY
MEATS
PERSONAL CARE
DELI
HOME CARE
EGGS
FROZEN FOODS
LIQUOR,WINE,BEER
PREPARED FOODS
SCHOOL AND OFFICE SUPPLIES
HOME AND KITCHEN I
HOME AND KITCHEN II
GROCERY II
SEAFOOD
LAWN AND GARDEN
CELEBRATION
PLAYERS AND ELECTRONICS
LADIESWEAR
PET SUPPLIES
LINGERIE
MAGAZINES
AUTOMOTIVE
BEAUTY
HARDWARE
HOME APPLIANCES
BABY CARE
BOOKS
製品種別
0.0 0.5 1.0 1.5 2.0 2.5 3.0 3.5
1e6
売上
sales
✓製品種別売上
✓期間：２０１７年８月１日から
２０１７年８月１５日まで
✓パンの売上：約４０.５万UTC
✓「パン」に焦点を当てた理由：
売上が大きい中で、最も消費期限が
短いと考えられたため

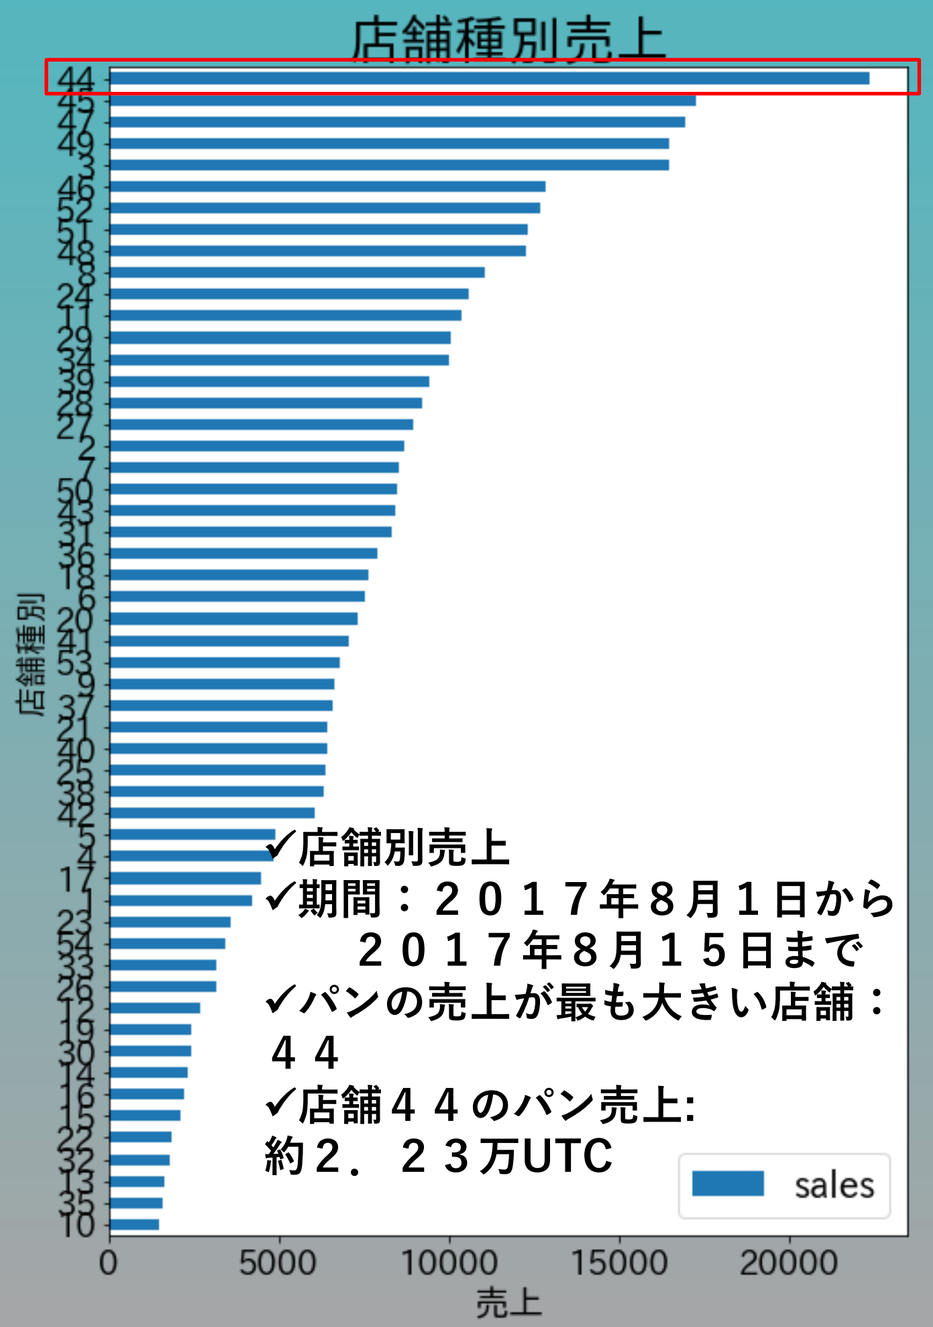
店舗種別売上
店舗種別
0 5000 10000 15000 20000
売上
sales
✓店舗別売上
✓期間：２０１７年８月１日から
２０１７年８月１５日まで
✓パンの売上が最も大きい店舗：
４４
✓店舗４４のパン売上:
約２．２３万UTC

EDA

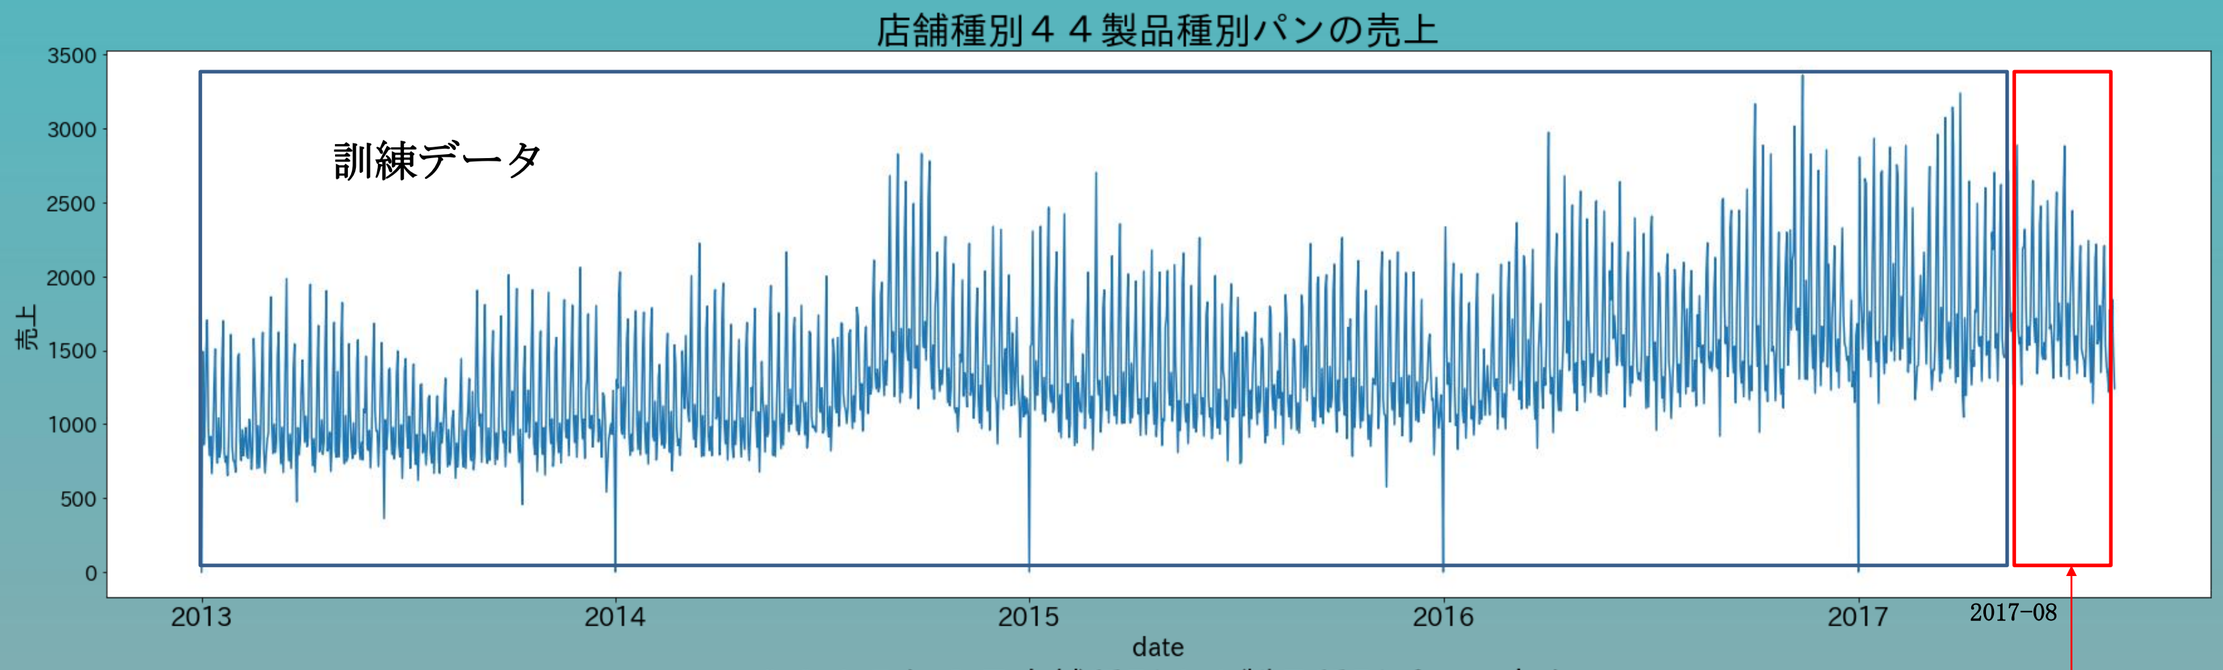
店舗種別４４製品種別パンの売上
訓練データ
売上
3500
3000
2500
2000
1500
1000
500
0
2013
2014
2015
2016
2017
2017-08
date

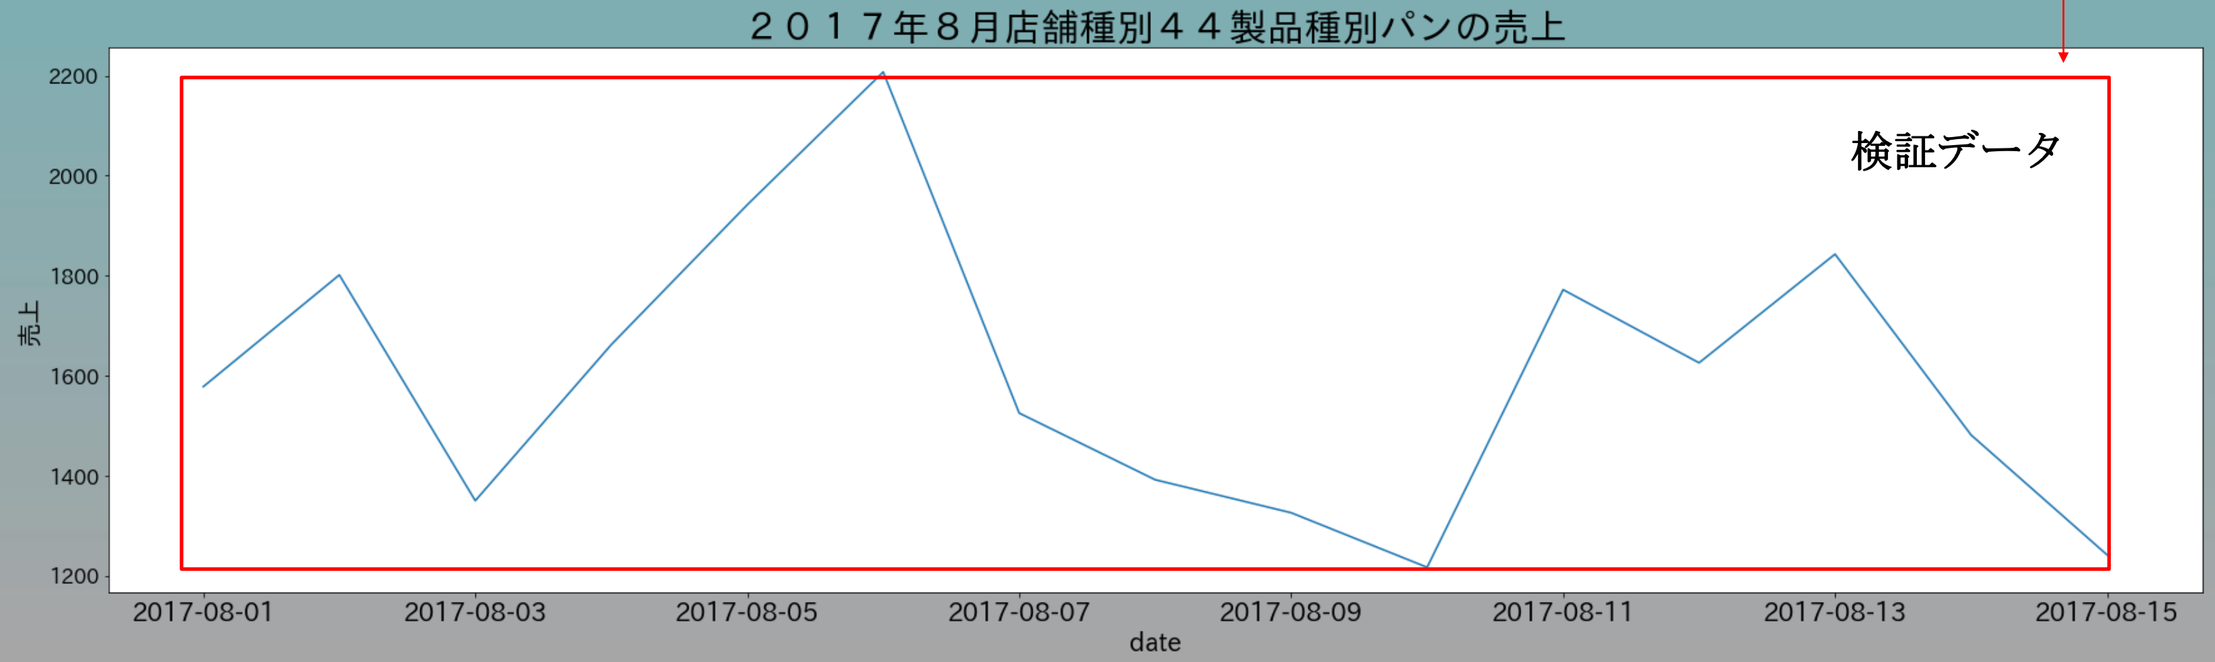
２０１７年８月店舗種別４４製品種別パンの売上
検証データ
売上
2200
2000
1800
1600
1400
1200
2017-08-01
2017-08-03
2017-08-05
2017-08-07
2017-08-09
2017-08-11
2017-08-13
2017-08-15
date

モデル開発(アルゴリズム＋最適化)

■アルゴリズム
勾配ブースティング

構築した決定木の損失関数の結果から
予測誤差を減らすように次々と決定木を直列（ブースティング）に構築・学習し学習結果を統合するモデル

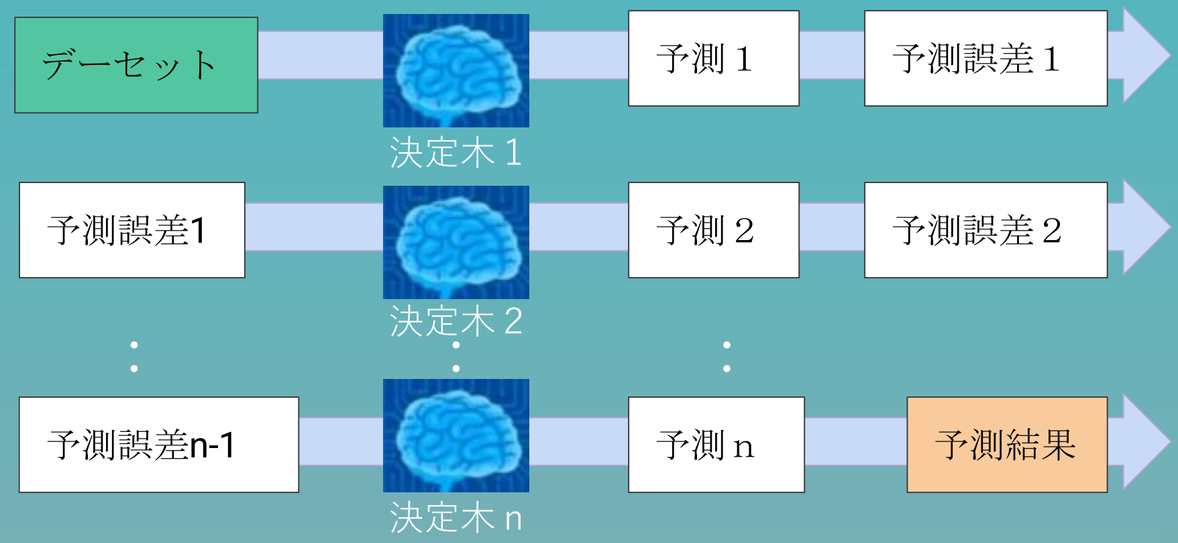

■解析条件

■アルゴリズム

■ ３種類

✓Lightgbm
✓Xgboost
✓Catboost

■交差検証法（設定：random_state=0,42,test_size=0.2）

■ ３種類

✓ k-fold（分割数:5）
✓ timeseriessplit（分割数：4）
✓ 交差検証なし(設定random_state=0,0)

■今回検討したパラメータ最適化

■ ２種類

✓ Optuna
✓ハイパーパラメータ調整なし
（設定：random_state=0,42,2020
timeout=1200）

施策改善と精度

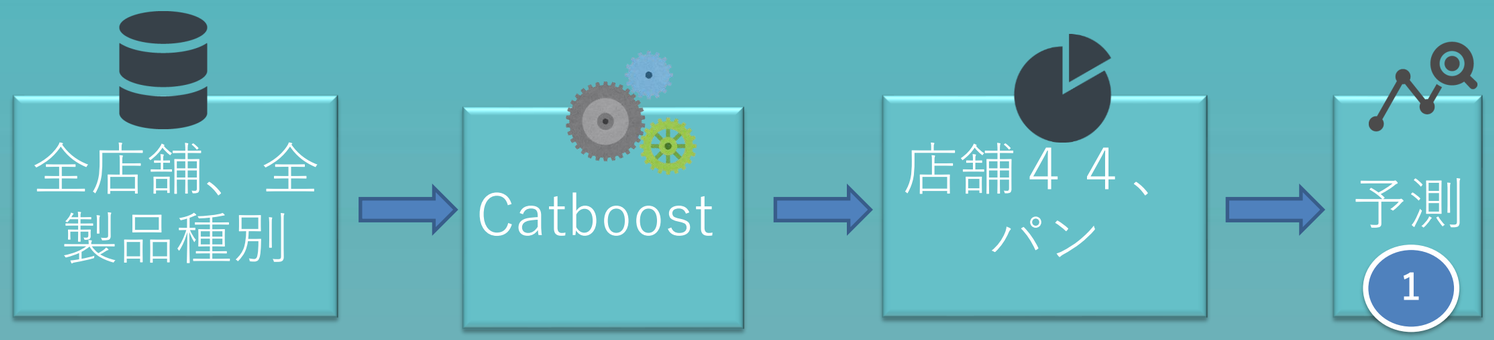

精度良い

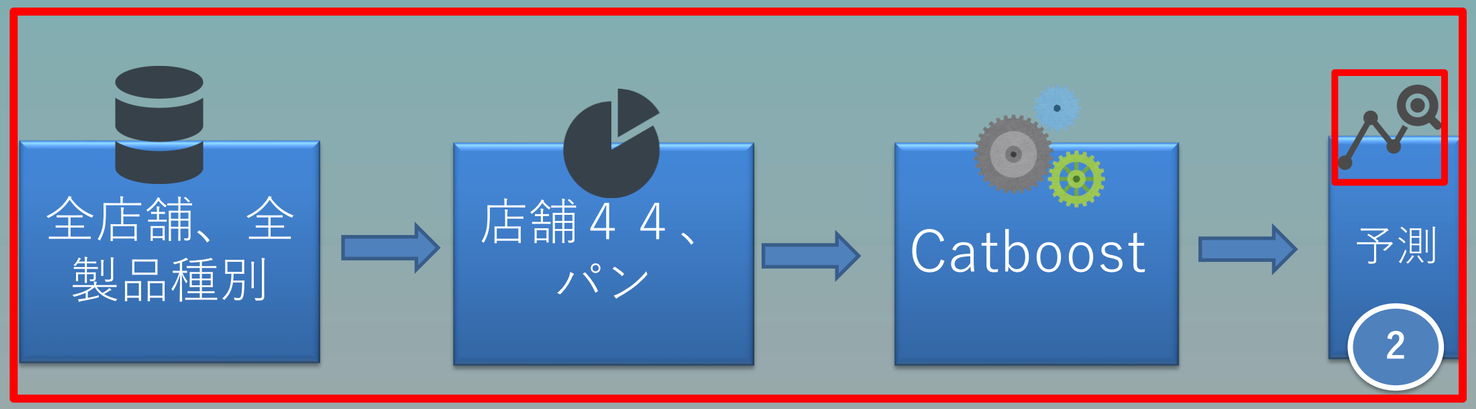

施策改善と精度

前処理：

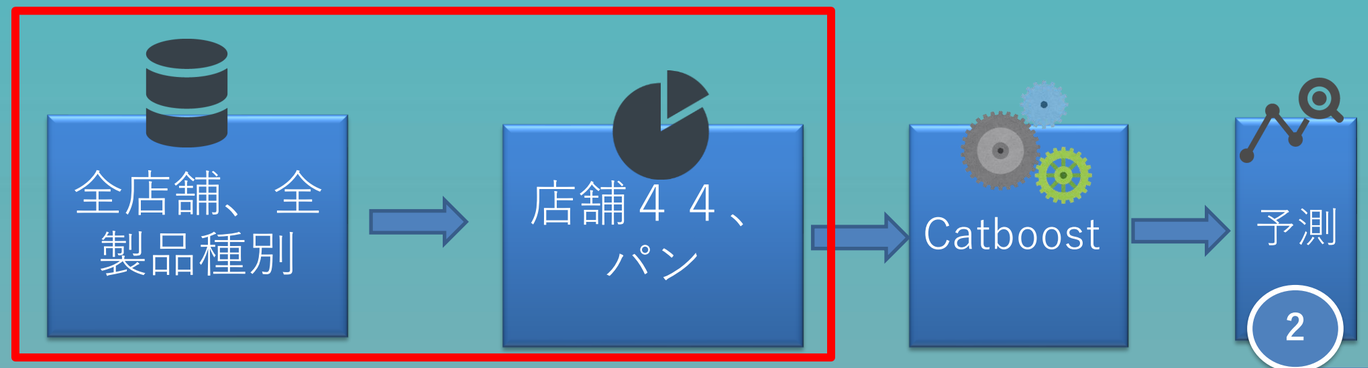

説明変数

日付　店舗番号　宣伝製品数

適合範囲名　説明　領収書発行数　政府都合の休日

クラスタ　店舗種別　WTI原油先物価格

製品種別　適合範囲　州　市　祝日種類

目的変数

売上

５ファイル結合、データ抽出、
文字列を数値に変換、説明変数削除

年　月　週　４半期　曜日

年初から１４日毎のカウント　年初から２８日毎のカウント

特徴量追加

施策改善と精度

モデル開発

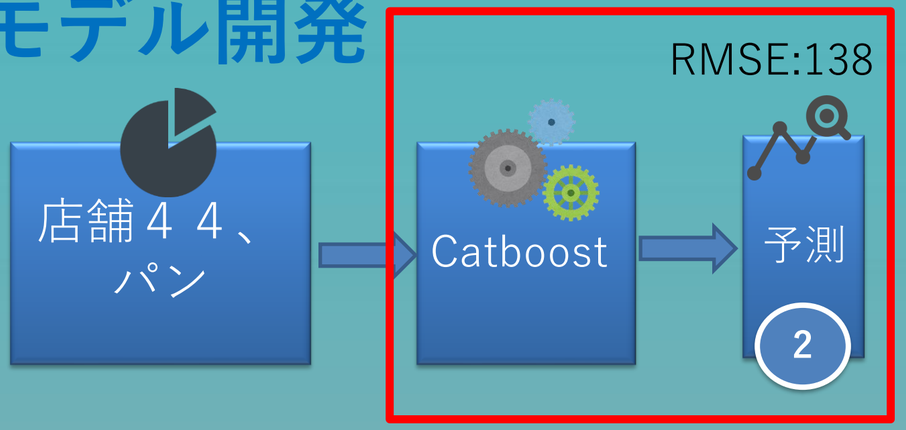

XGBOOST	42,none	交差検証 timeseriessplit
LightGBM	42,0	交差検証 KFOLD
Catboost	42,2020	
	0,0	交差検証なし

２０１７年８月店舗種別４４製品種別パンの売上

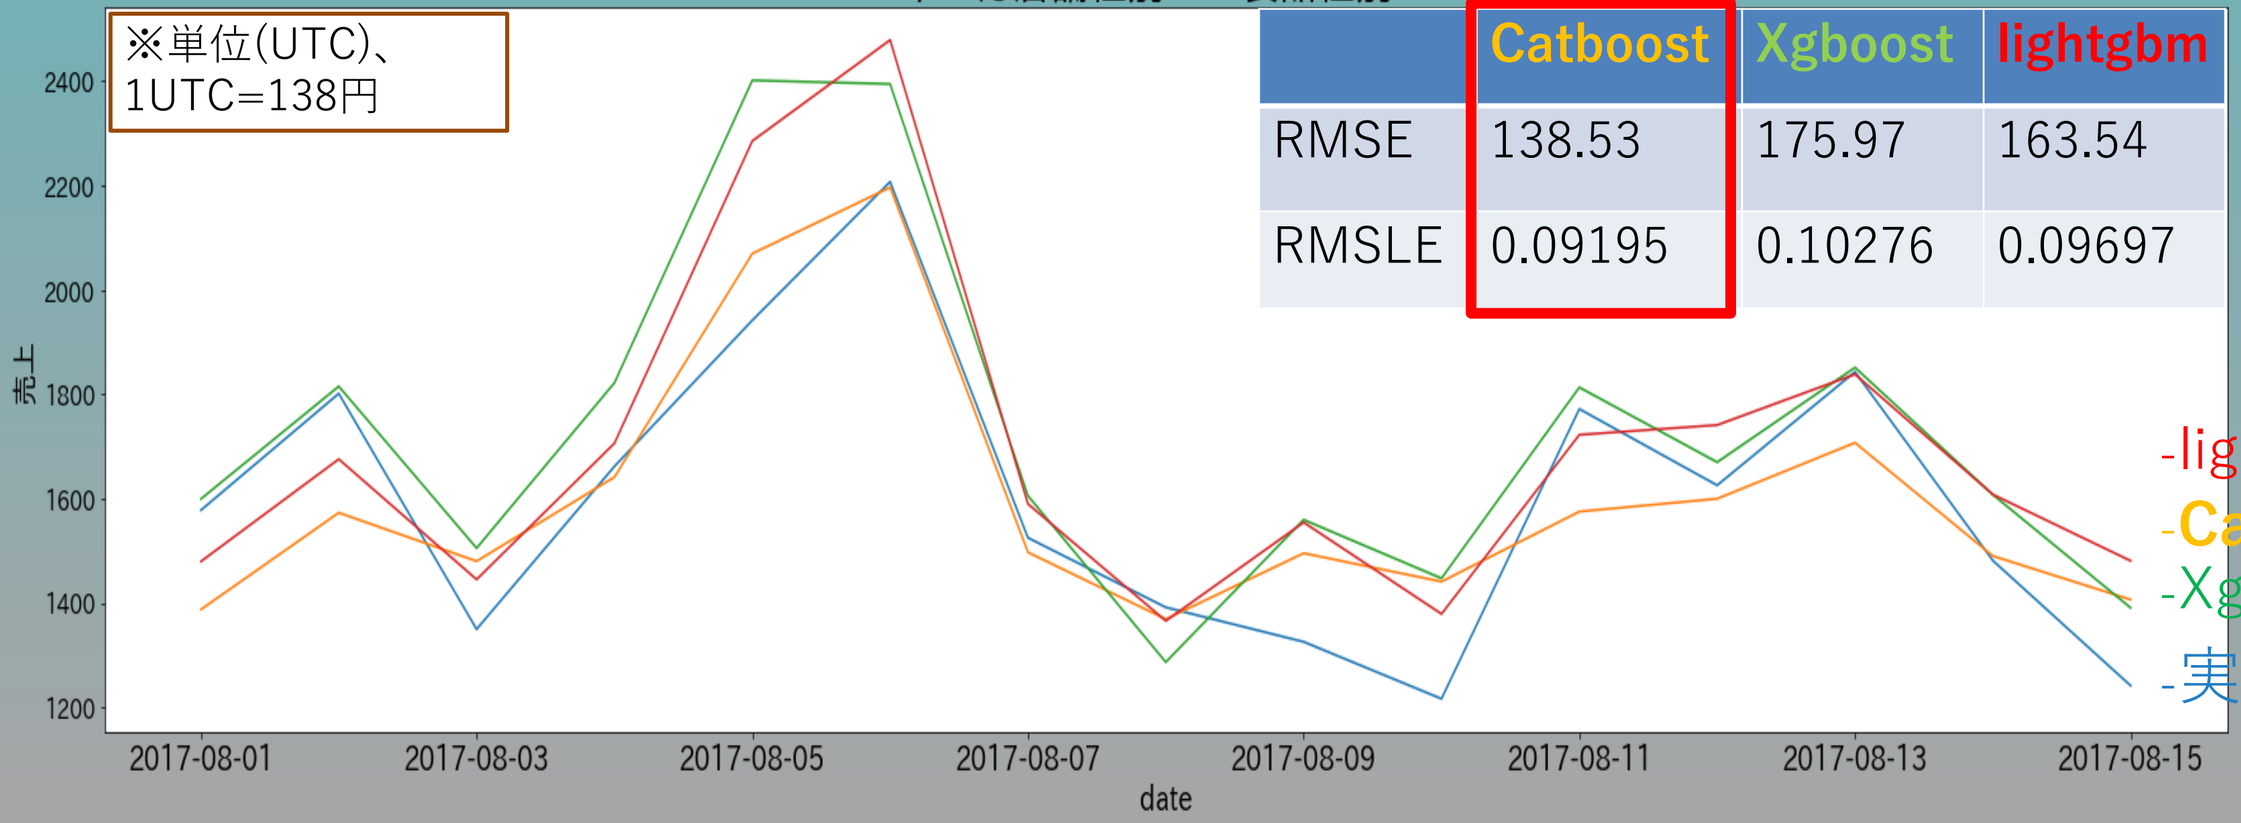

	Catboost	Xgboost	lightgbm
RMSE	138.53	175.97	163.54
RMSLE	0.09195	0.10276	0.09697

施策改善と精度

精度

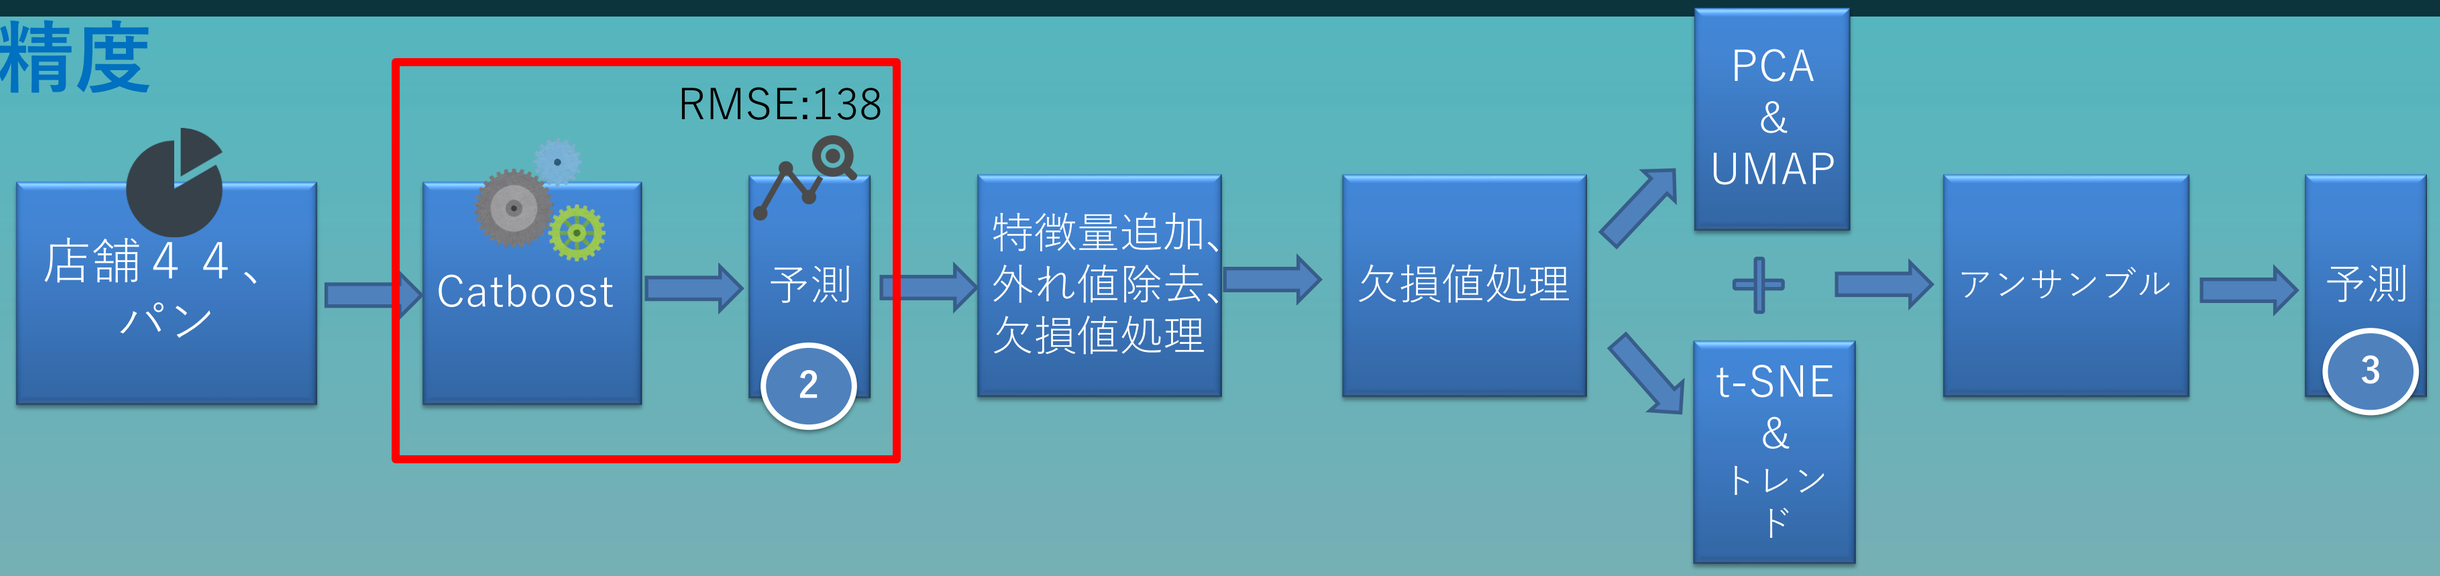
店舗４４、パン
Catboost
RMSE:138
予測
2
特徴量追加、外れ値除去、欠損値処理
欠損値処理
PCA & UMAP
t-SNE & トレンド
アンサンブル
予測
3

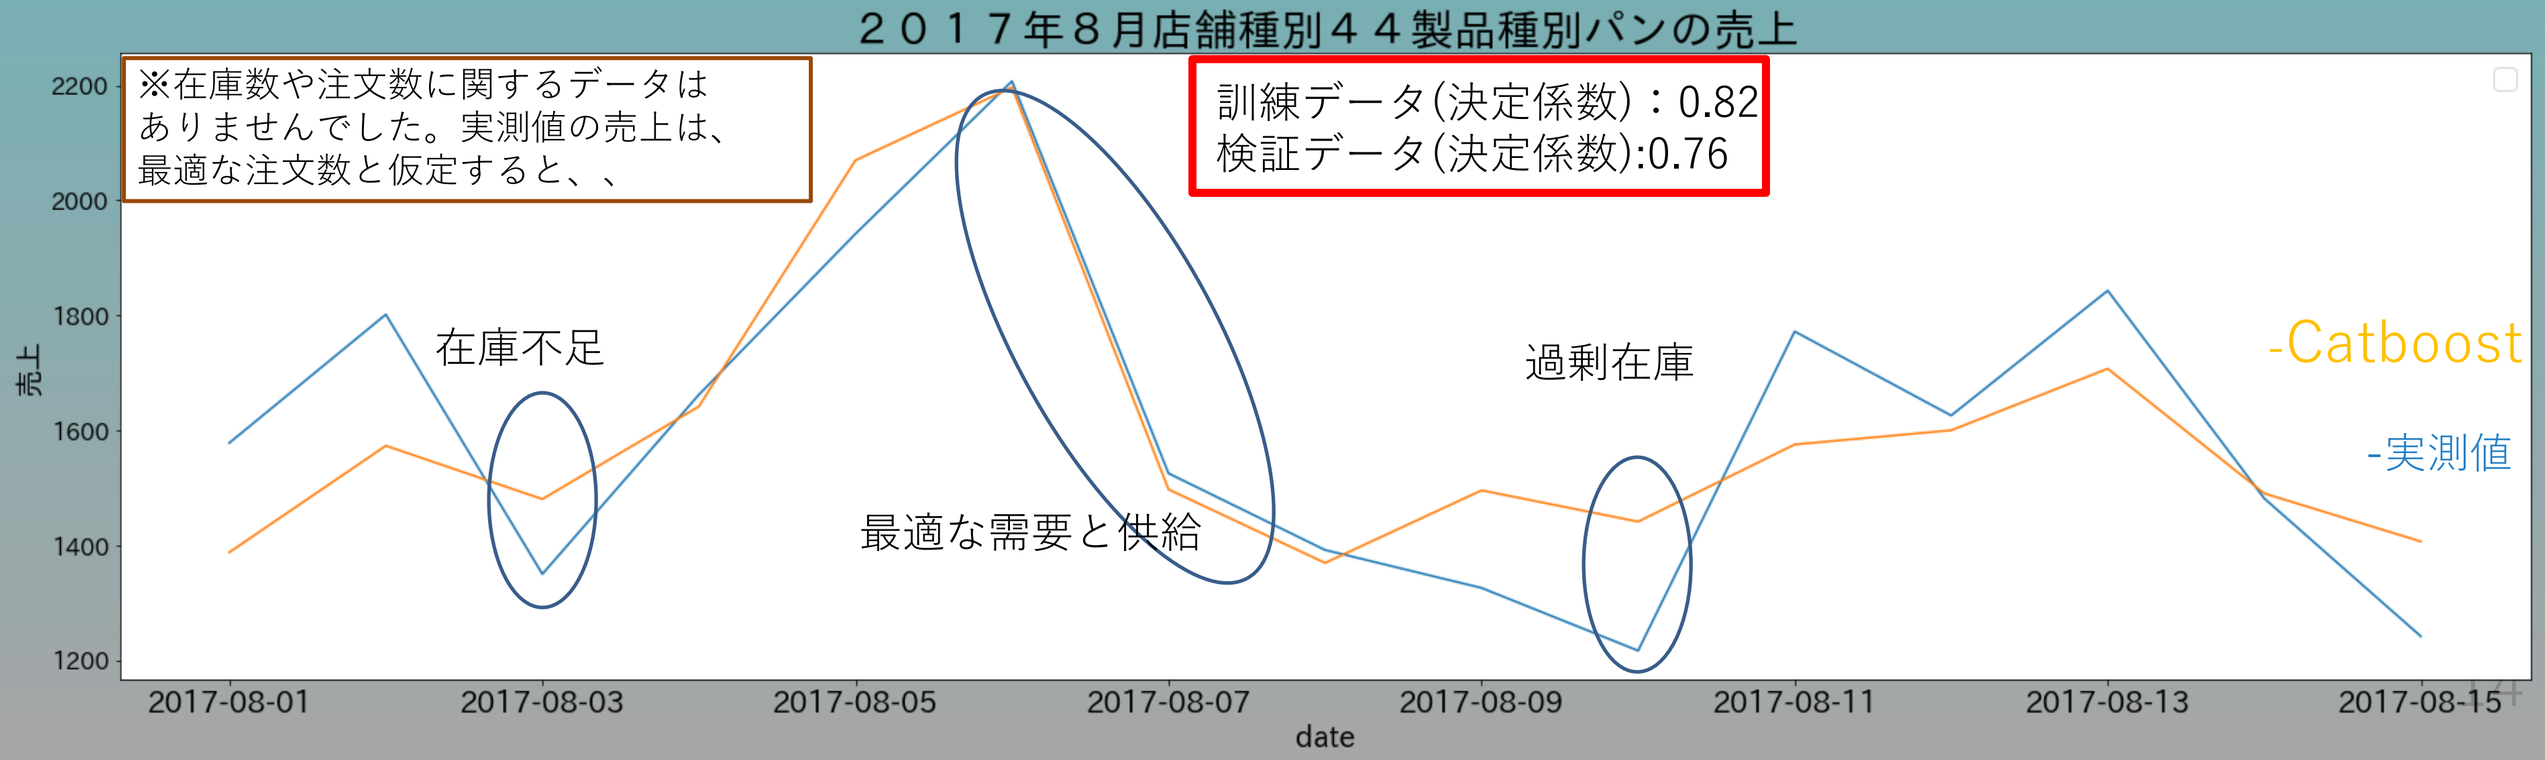
２０１７年８月店舗種別４４製品種別パンの売上
※在庫数や注文数に関するデータはありませんでした。実測値の売上は、最適な注文数と仮定すると、、
訓練データ(決定係数)：0.82
検証データ(決定係数):0.76
在庫不足
最適な需要と供給
過剰在庫
-Catboost
-実測値
売上
2200
2000
1800
1600
1400
1200
2017-08-01
2017-08-03
2017-08-05
2017-08-07
2017-08-09
2017-08-11
2017-08-13
2017-08-15
date

施策改善と精度

特徴量作成

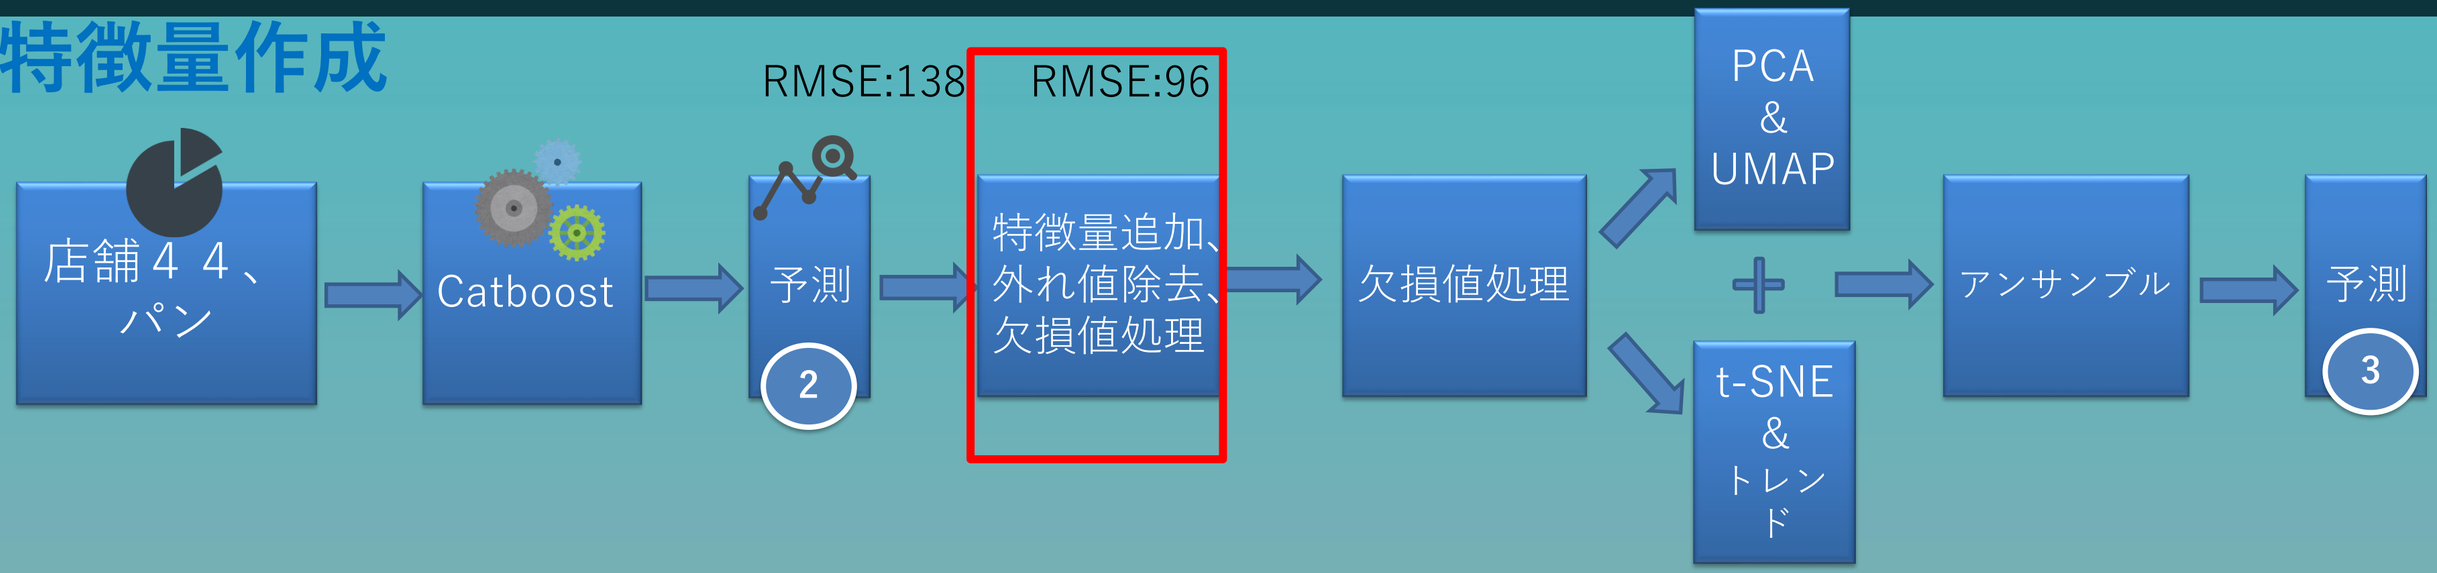

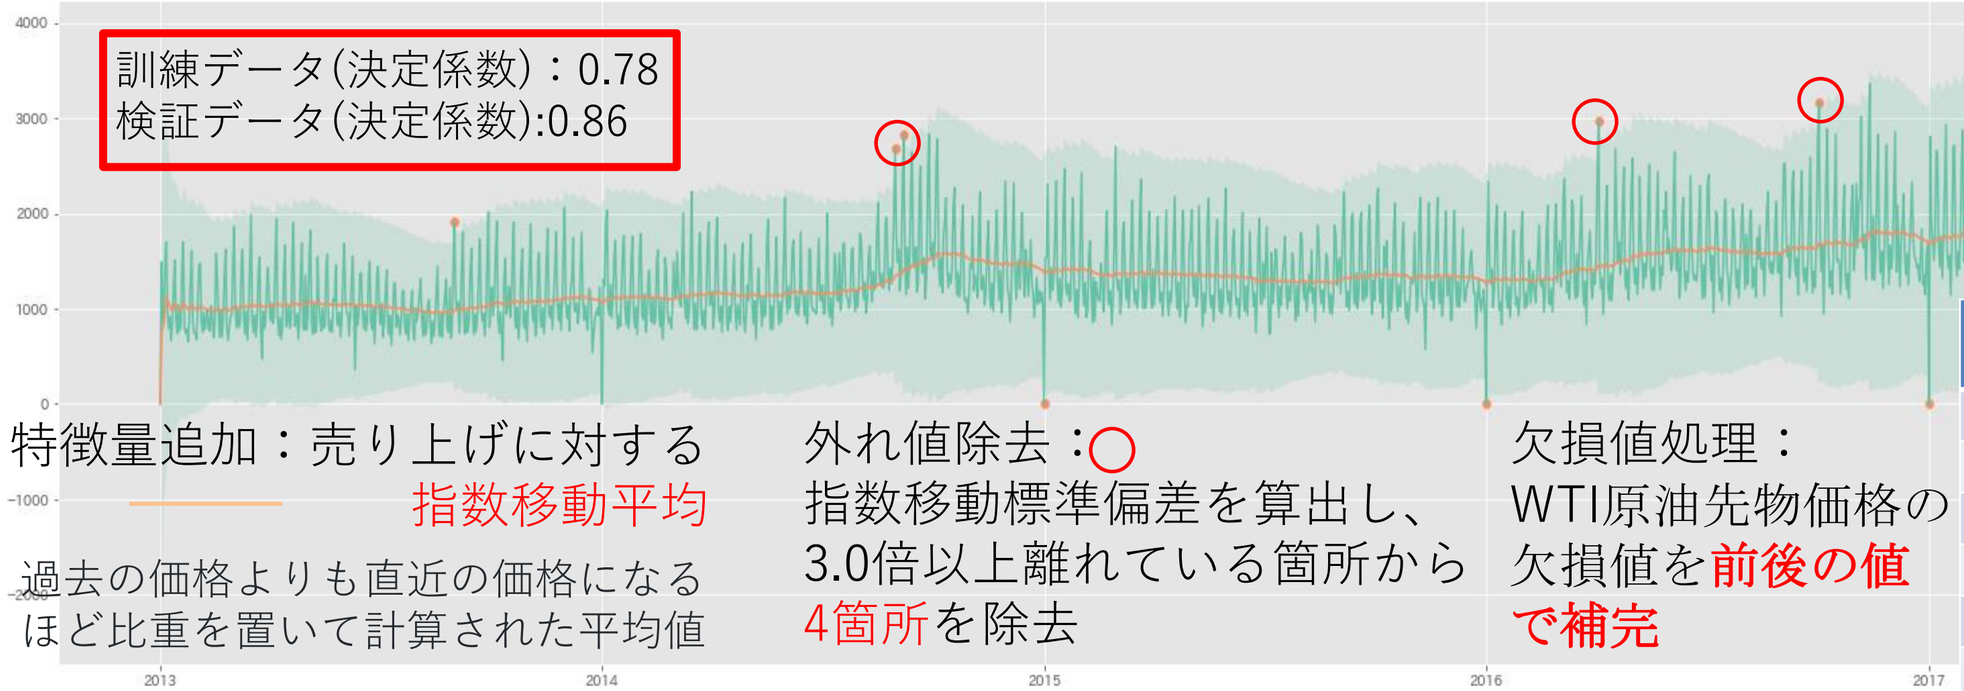

訓練データ(決定係数)：0.78
検証データ(決定係数):0.86

特徴量追加：売り上げに対する指数移動平均

過去の価格よりも直近の価格になるほど比重を置いて計算された平均値

外れ値除去：○
指数移動標準偏差を算出し、3.0倍以上離れている箇所から4箇所を除去

欠損値処理：
WTI原油先物価格の欠損値を**前後の値で補完**

日	oil値	.fill().bfill()
1	1	1
2	10	10
3	NaN	10
4	NaN	NaN
5	NaN	100
6	100	100

施策改善と精度

次元削減

RMSE:138　RMSE:96

店舗４４、パン → Catboost → 予測 ② → 特徴量追加、外れ値除去、欠損値処理 → 欠損値処理 → アンサンブル → 予測 ③

RMSE:85 PCA & UMAP

＋

RMSE:86 t-SNE & トレンド

次元削減をするために、欠損値処理を行った。

欠損値処理

領収書発行数に欠損値がある日を除去			
2013-01-01	2014-01-01	2015-01-01	2016-01-01
2016-01-03	2016-01-04	2017-01-01	

PCA & UMAP

次元削減
PCA:23→ 6
UMAP:6→2
RMSE:85

t-SNE

次元削減
t-SNE:23→2
RMSE:87

トレンド

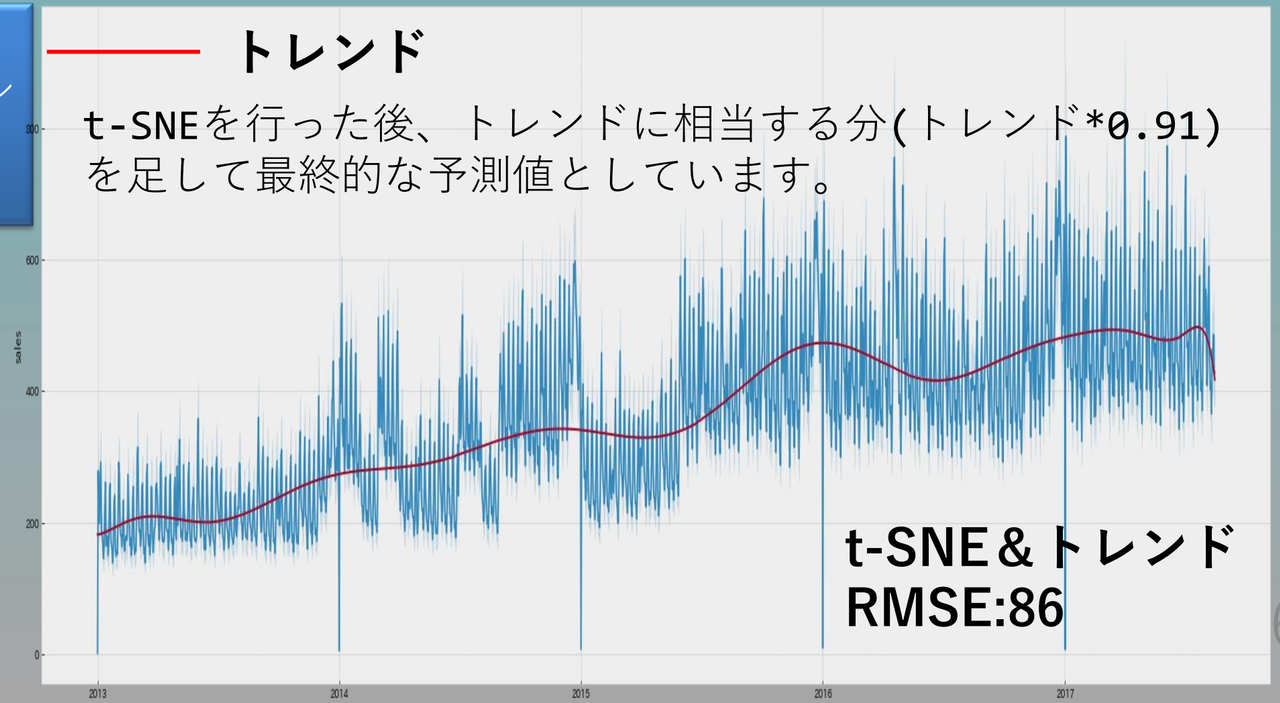

施策改善と精度

アンサンブル

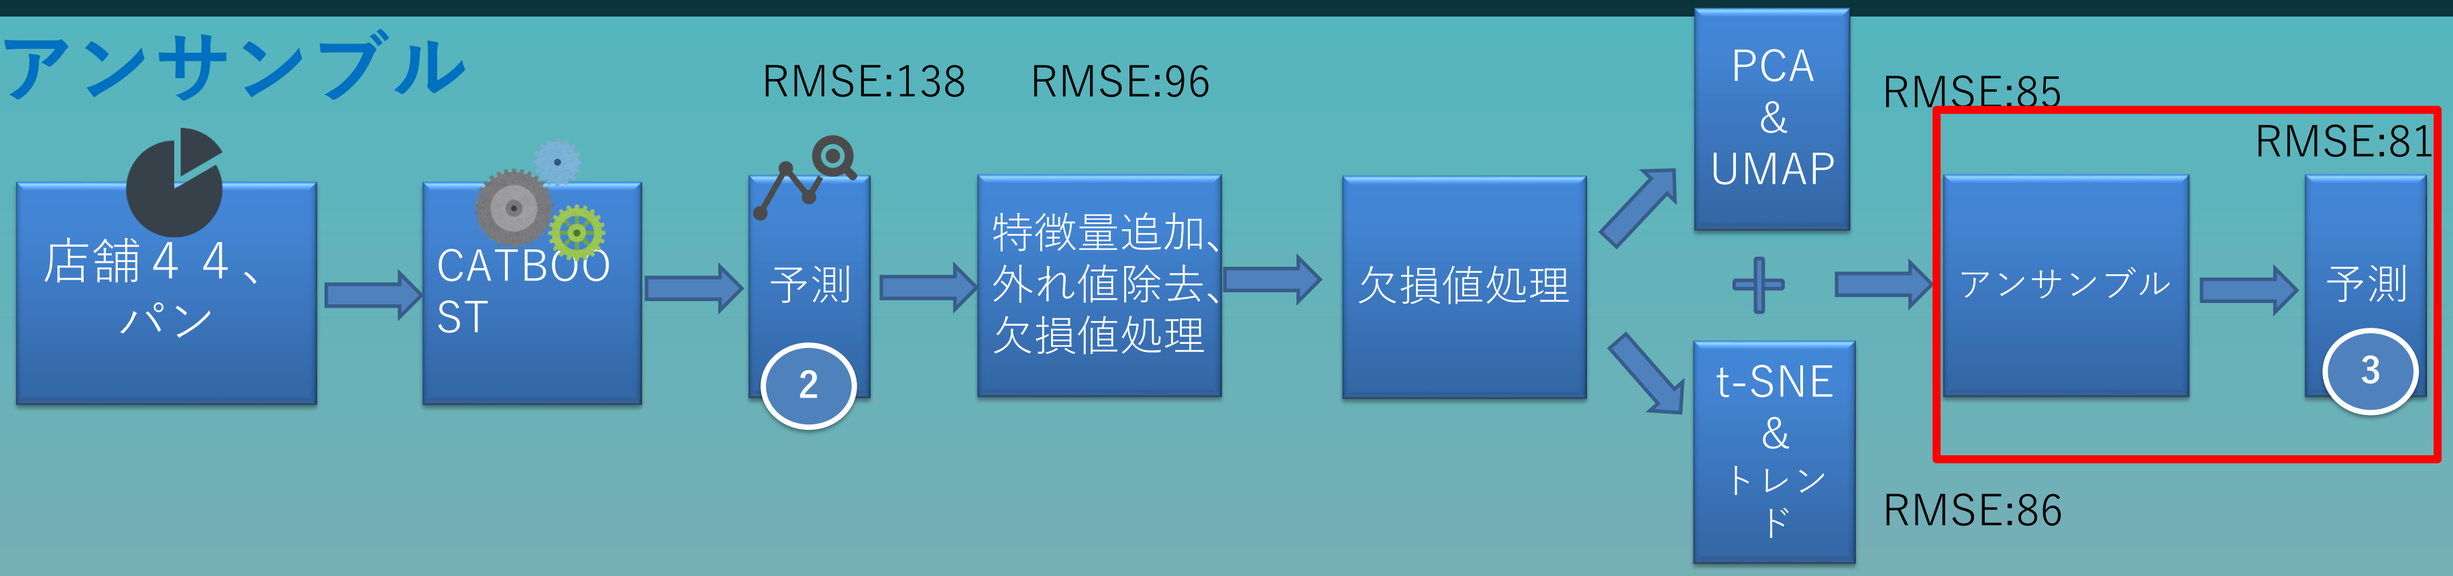

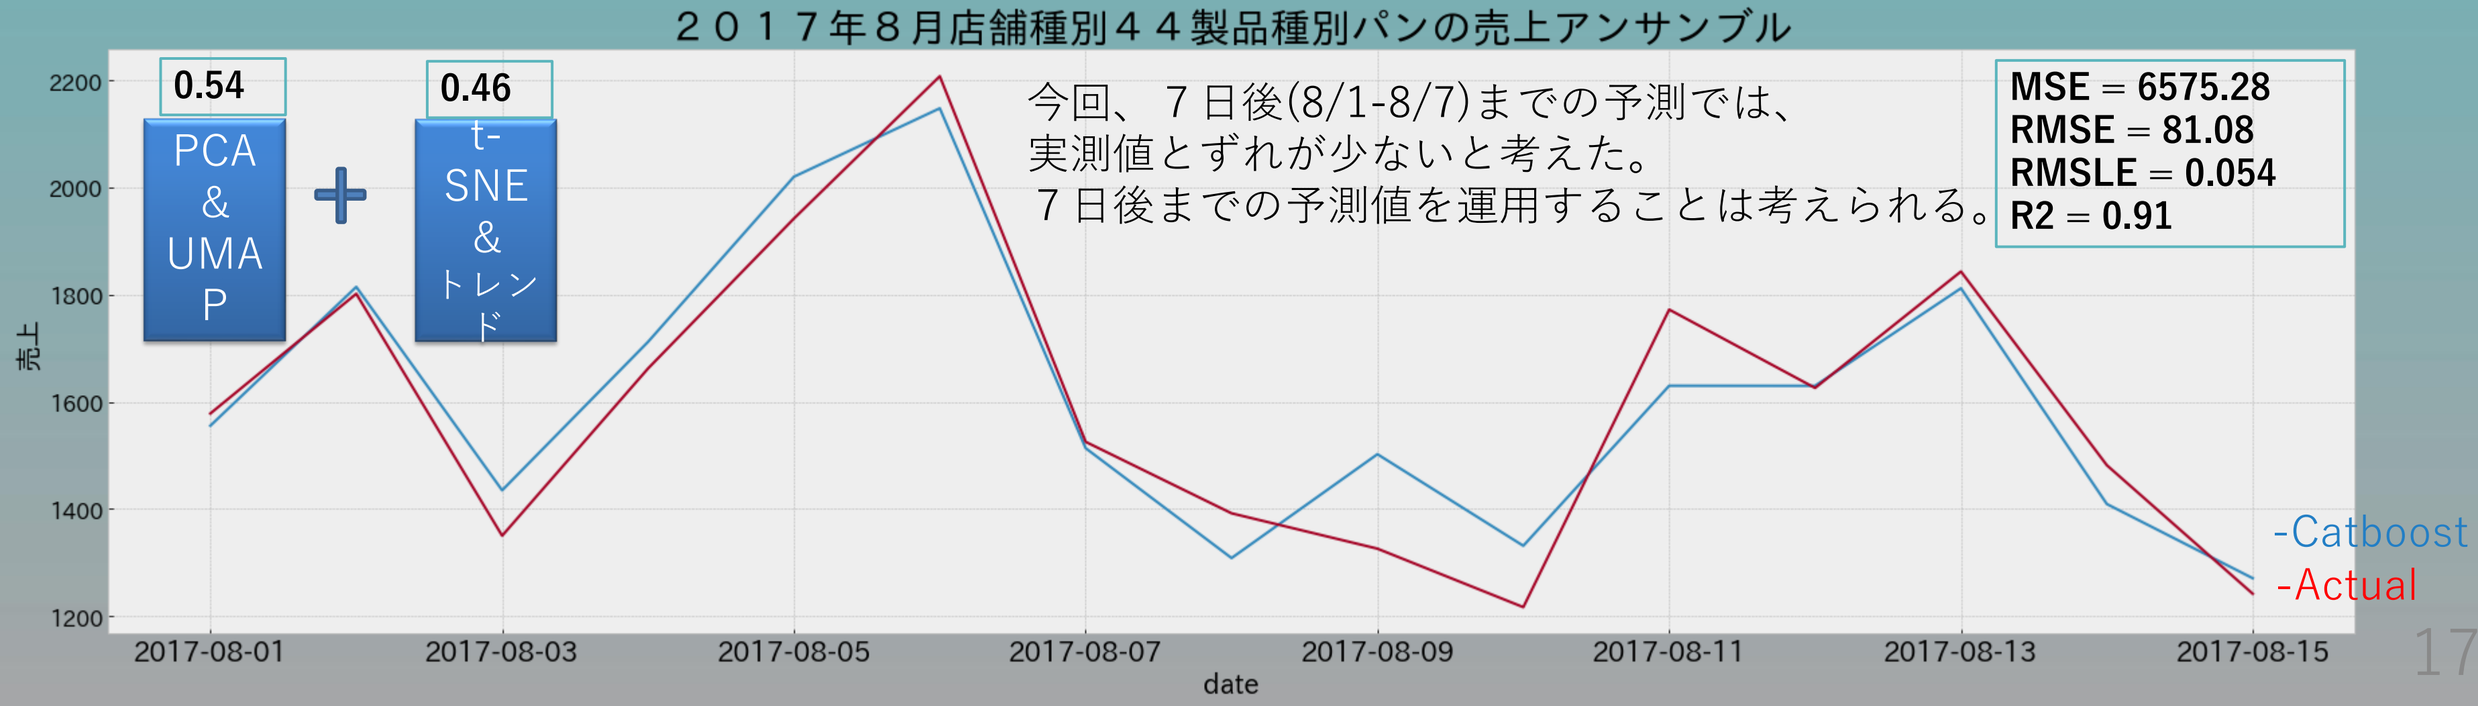

1 モデルを使った運用の姿（再掲）

2 運用時のモデルの精度確認と更新計画

3 ここまででわかったこと

まとめ

取り組みの方向性

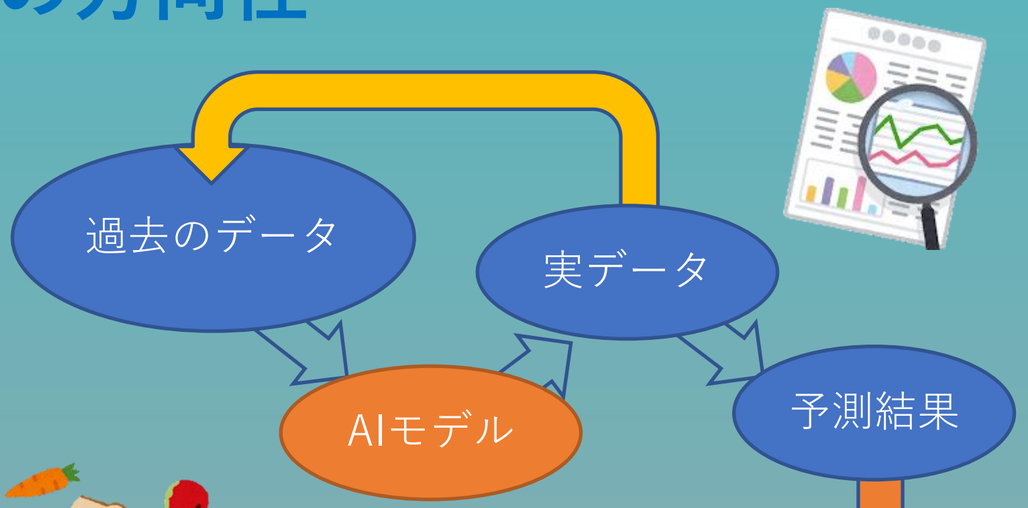

過剰在庫
→食品ロス

最適な需要と供給

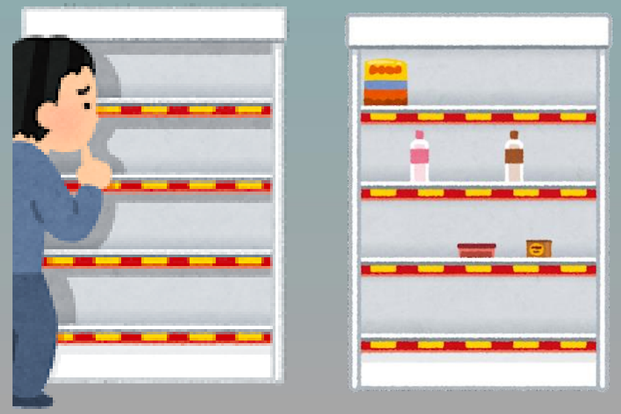

在庫不足
→売上減少、顧客満足度の低下

売上向上と過剰在庫削減

予測結果をもとに食品の買い付け

運用時のモデルの精度確認と更新計画

過去のデータ → AIモデル → 予測結果 → 評価結果

売上の予測

実際の需要供給の差

売上実績データ

「収入＋α」が最大になるようパラメータ調整

予測結果をもとに発注を増減した場合の実データにて「収入の増減」を評価

ここまででわかったこと

✓在庫数、商品単価、注文商品数の説明変数があれば、過剰在庫や、過不足しない発注数を決められる。
次のアクションとして、在庫数、商品単価、商品数のデータが必要。

✓カテゴリ変数が多い特徴量に有効なアルゴリズムCatboostモデル(random_state:0,0、交差検証なし)の精度が高かった。

✓指数移動平均の特徴量追加、次元削減、トレンド追加、アンサンブルを行うことは、精度向上につながった。

✓データが少ない中で、７日間目までは活用が可能なレベルまでに至った。

✓在庫を抱える業務では、時系列解析が活かせる。

今回は、限定されたデータから以上のことが分かった。

今後、業務において、データなどが揃えば、このモデルが活用されると思われる。

ご清聴ありがとうございます

NeuroDiveFukuoka　　小林稔征