大気汚染測定値の予測

NeuroDiveFukuoka
小林稔征

2022年11月25日

目 次

Ⅰ．　成果物概要
Ⅱ．　ビジネスでのAIモデル企画
Ⅲ．　取り組みの概要
Ⅳ．　モデル概要
Ⅴ．　外れ値処理
Ⅵ．　異常値処理
Ⅶ．　特徴量作成
Ⅷ．　バリデーション
Ⅸ．　まとめ

I

成 果 物 概 要

課題テーマ6：　大気汚染測定値の予測(種別：時系列)

Kaggle	**Tabular Playground Series - Jul 2021** https://www.kaggle.com/c/tabular-playground-series-jul-2021
課題タスク	説明変数（気温、絶対湿度、相対湿度、センサーデータ5つ）を用いて、目的変数(CO,NOx,ベンゼン)を予測する。(絶対湿度:空気中に含まれる水分量（g/㎥）、相対湿度:空気中に含まれる水分の割合（%）)
テーマ概観	✓直近で時系列解析をしてたから、とりかかりやすそう ・欠損値がないので、他のことで創意工夫をしないといけない ✓環境調査の経験があり、活かせるドメイン知識があるか不明だが、興味を持った ✓センサーデータを活用した予測は生産工場で重要である ✓大気汚染防止はますます厳しくなるので重要課題である

元データ

train.csv(検証用)

データ期間
2010/03/10 18:00:00
– 2011/01/01 00:00:00

説明変数

目的変数

時間	気温	相対湿度	絶対湿度	sensor_1	sensor_2	sensor_3	sensor_4	sensor_5	CO	ベンゼン	NO x
2010/3/10 18:00	13.1	46	0.7578	1387.2	1087.8	1056	1742.8	1293.4	2.5	12	167.7
2010/3/10 19:00	13.2	45.3	0.7255	1279.1	888.2	1197.5	1449.9	1010.9	2.1	9.9	98.9
2010/3/10 20:00	12.6	56.2	0.7502	1331.9	929.6	1060.2	1586.1	1117	2.2	9.2	127.1
2010/3/10 21:00	11	62.4	0.7867	1321	929	1102.9	1536.5	1263.2	2.2	9.7	177.2
2010/3/10 22:00	11.9	59	0.7888	1272	852.7	1180.9	1415.5	1132.2	1.5	6.4	121.8

test.csv(kaggle用)

データ期間
2011/01/01 00:00:00
– 2011/04/04 14:00:00

時間	気温	相対湿度	絶対湿度	sensor_1	sensor_2	sensor_3	sensor_4	sensor_5
2011/1/1 0:00	8	41.3	0.4375	1108.8	745.7	797.1	880	1273.1
2011/1/1 1:00	5.1	51.7	0.4564	1249.5	864.9	687.9	972.8	1714
2011/1/1 2:00	5.8	51.5	0.4689	1102.6	878	693.7	941.9	1300.8
2011/1/1 3:00	5	52.3	0.4693	1139.7	916.2	725.6	1011	1283
2011/1/1 4:00	4.5	57.5	0.465	1022.4	838.5	871.5	967	1142.3

II

ビジネスでの
AIモデル企画

AIモデル企画の構成要素

1 業務課題

CO,NOx,ベンゼンの大気汚染測定値を予測する
工場である場合、高値が出ないように対処する

2 課題のためにAIで何を行うか

大気汚染測定値の予測モデルを学習、回帰問題

3 データ

ファイル
✓train.csv
✓test.csv

説明変数(8種類)
(気温、相対湿度、絶対湿度、センサー1～センサー5)
目的変数(3種類)

trainデータ期間
2010年3月 – 2010年12月
testデータ期間
2011年1月 – 2011年4月

4 使用するAI技術

機械学習：教師あり学習
✓lightgbm
✓randomforest
✓extratrees
など、その他回帰アルゴリズム

5 必要な前処理

✓外れ値処理
✓異常値処理
✓特徴量追加

6 評価指標

AIモデルの評価
・RMSLE(誤差：値が0に近いほど良い)

ビジネス
✓大気汚染防止法などの環境基準

7 必要なタスク

✓データセットをFix
✓運用フローの設計
✓各手法での精度評価、パラメータ調整
✓どのアプローチが良さそうか。
✓更なるパラメータ調整

8 モデル運用フロー

実務の運用フロー
✓単純な閾値処理(環境基準)
✓予測期間を決める
・工場で運用する場合
✓異常な予測(兆候)が出た場合、実際に発生しないように対処する
・公的機関で運用する場合
環境対策の方針決めの参考データにする

9 理想のアウトプット（目的変数）

3つの大気汚染測定値（予測）

Ⅲ

取り組みの概要

仮説

大気汚染物質の連続測定とベンゼン濃度の経年変化

伏見　暁洋[1)]・原　千陽[1)]・川島　洋人[1)]・鈴木　宏典[1)]・増田　厚[2)]・梶原　秀夫[3)]・花井　義道[1)]・中西　準子[1)]

Continuous Monitoring for Air Pollutants and Long-Term Trend of Benzene Level

Akihiro FUSHIMI[1)], Chiharu HARA[1)], Hiroto KAWASHIMA[1)], Hironori SUZUKI[1)], Atsushi MASUDA[2)], Hideo KAJIHARA[3)], Yoshimichi HANAI[1)] and Junko NAKANISHI[1)]

Synopsis

Ambient levels of benzene, a known human carcinogen, NOx, CO and criteria pollutants are dominated by emissions from automobiles. Ambient levels of benzene, NOx, CO were monitored continuously in order to predict the nationwide benzene exposure levels by using the relationship between benzene and NOx or between benzene and CO. NOx and CO were found to be reliable predictors of benzene levels. The data of $PM_{2.5}$, aromatic compounds and weather conditions, those were also monitored continuously, were reported. The relationship between benzene and $PM_{2.5}$ or between benzene and aromatic compounds were reported. The benzene level are expected to decrease as a result of the regulation of benzene content of gasoline. The long-term trend of benzene level was examined with monitoring data.

1．はじめに

ベンゼンは白血病の原因となる発ガン性物質であり，大気中のベンゼンによる健康影響が懸念されている。環境庁はベンゼンを優先取り組み物質に指定し，平成９年に環境基準値を年平均3μg/m³と制定した。また，平成12年１月にはガソリン中のベンゼン含有率の規制値が5vol%から1vol%に強化された。

大気中のベンゼン濃度は多数の要因により大きく変動し，数回の散発的な実測では健康影響の評価を行うことは困難である（内山ら，1991；中西，

大気汚染物質の曝露評価を行う方法に，全国で監視体制が整っている物質の測定データを活用する方法がある（Macintosh，1995）。ベンゼンは自動車の寄与が大きい物質である（中央環境審議会，1996）。全国で測定されている大気汚染物質のうち，ベンゼンと同様に自動車の寄与が大きい物質は窒素酸化物（NOx）と一酸化炭素（CO）である（環境庁編，1998）。したがって，ベンゼンと両物質の濃度には高い相関があると考えられ，ベンゼン濃度を予測するための指標物質として期待される。

一酸化炭素濃度を用いたベンゼン濃度の推定方法*

西　原　幸　一**・日　野　康　良**・藤　田　淳　二**・横　井　　聰**

キーワード　①ベンゼン　②一酸化炭素　③有害大気汚染物質　④環境濃度推定　⑤季節変動

要　　旨

環境大気中のベンゼン濃度を，一酸化炭素の常時監視測定値を用いて推定するため，一酸化炭素とベンゼンの関係を検討した。この結果１％の危険率で有意の相関があったが，

科学技術論文からわかること

・目的変数であるCO、ベンゼン、Noxは、正の相関がある
→他の2つの目的変数の予測値を説明変数として
取り入れることが精度向上に繋がると考えました。

取り組みの方向性

※目的変数COを推論する場合

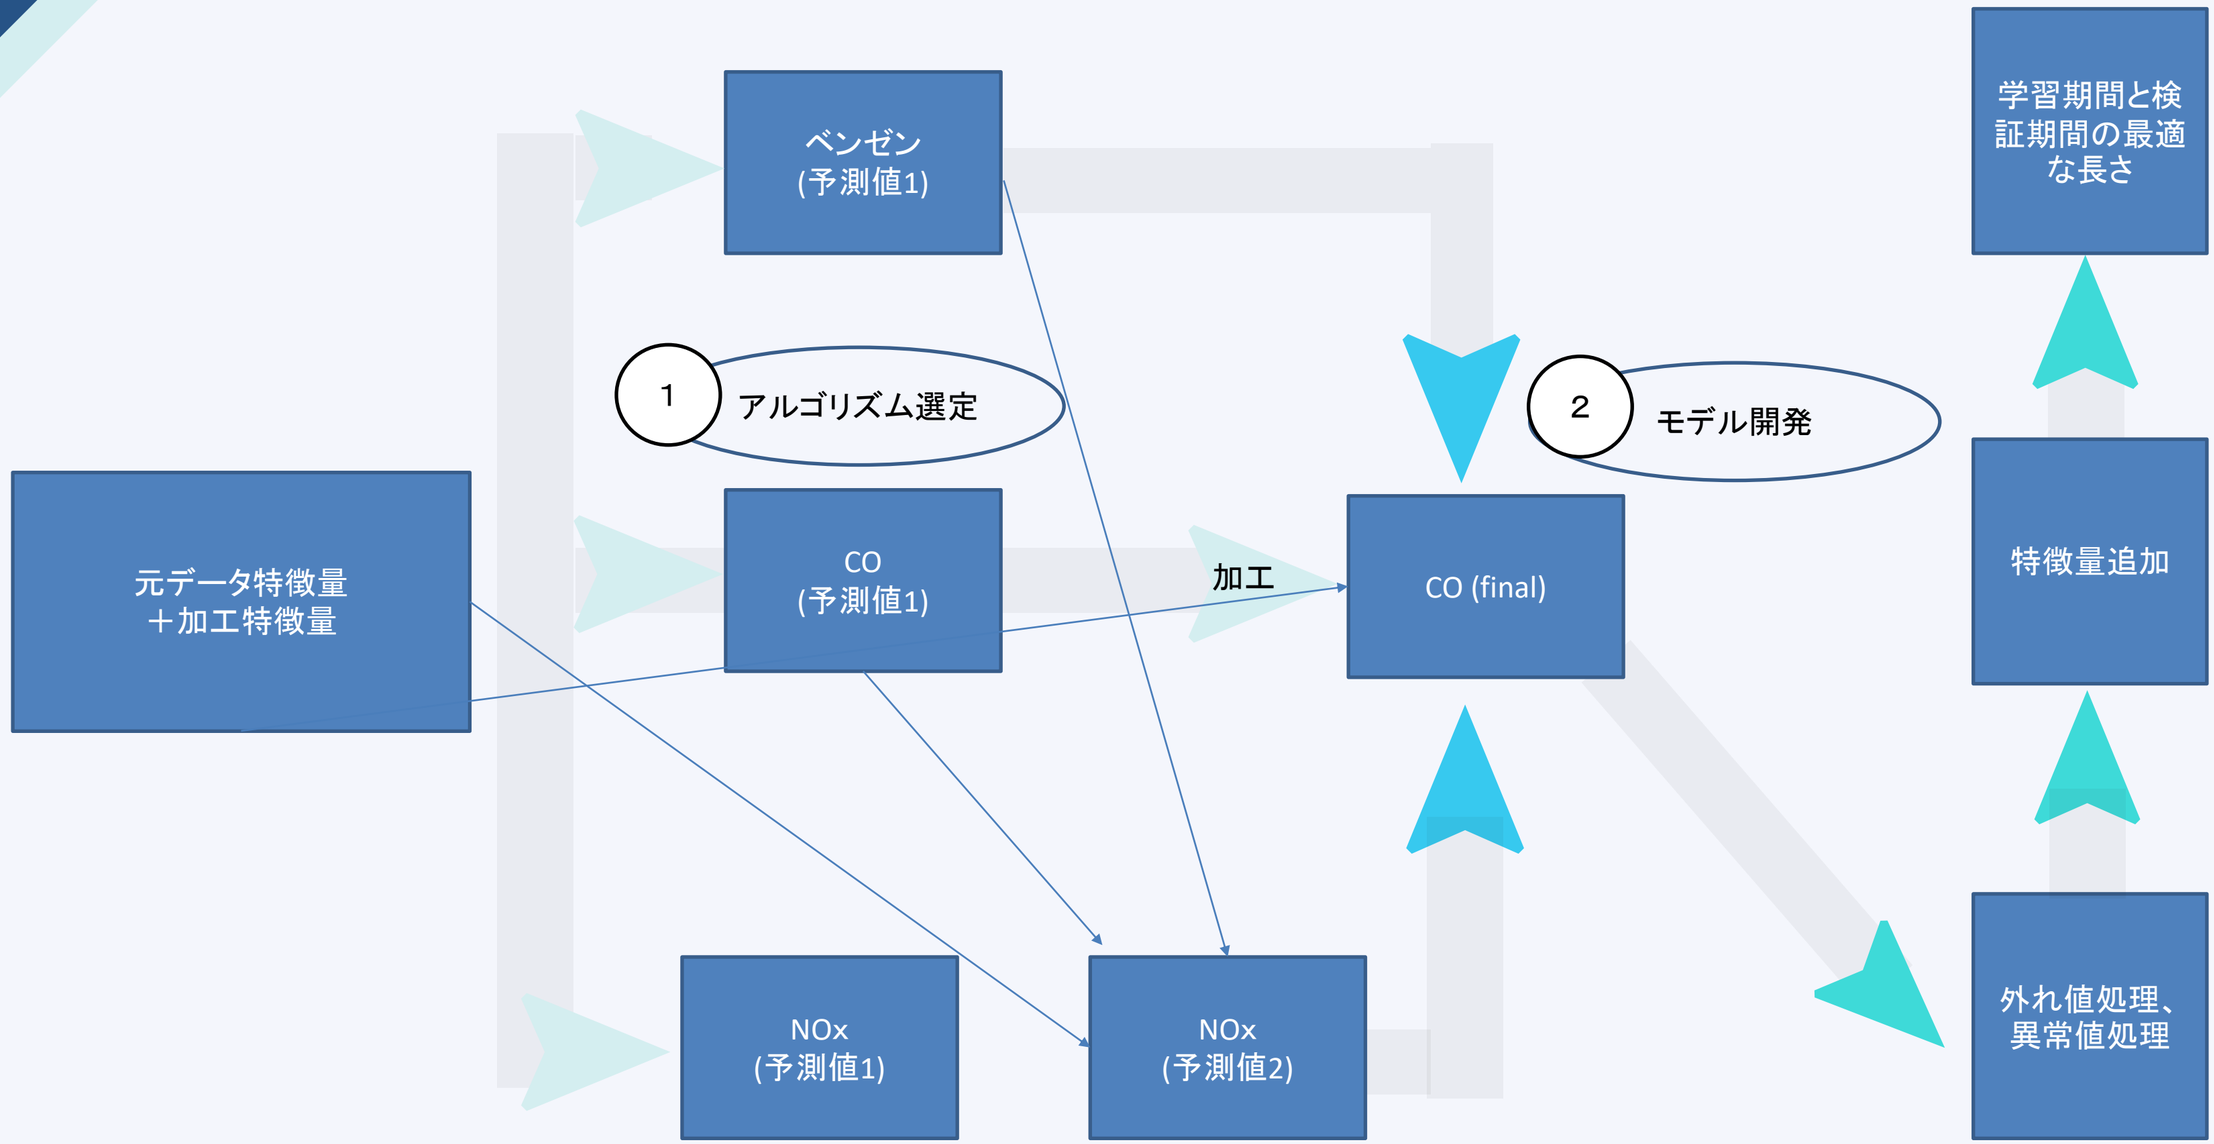

精度結果

Kaggle private score:0.21611(770/1293)
public score:0.24969(558/1293)

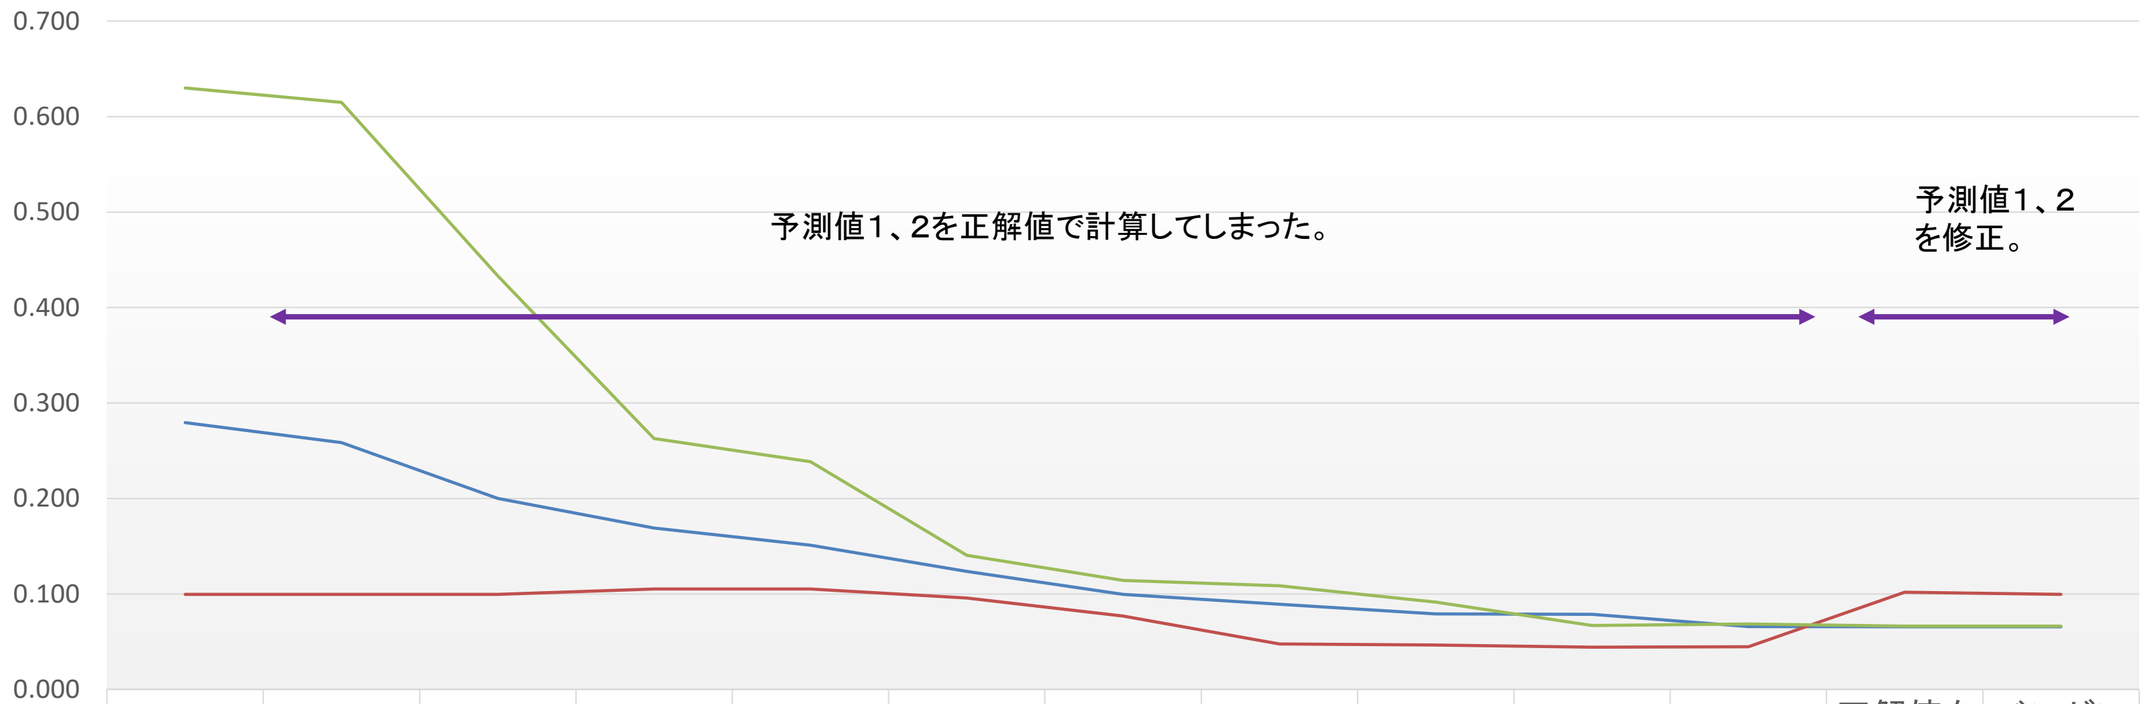

	アルゴリズム選定 11/7	モデル開発11/10	外れ値処理11/14	異常値処理11/15	shift1+2 11/16	rolling3+240(mean) 11/16	rolling3+240(min) 11/17	rolling3+240(max) 11/17	ewm3+240(mean) 11/17	wma3+240(mean) 11/17	rolling(max-min) 11/17	正解値を予測値に変更 11/21	ベンゼンを初期に戻す 11/22
CO	0.280	0.259	0.200	0.169	0.151	0.124	0.100	0.089	0.079	0.079	0.066	0.066	0.066
benzene	0.100	0.100	0.100	0.105	0.105	0.096	0.077	0.048	0.047	0.044	0.045	0.102	0.100
Nox	0.630	0.615	0.433	0.263	0.238	0.141	0.114	0.109	0.092	0.067	0.069	0.066	0.066

Ⅳ

モデル概要

アルゴリズム選定

1 ターゲットごとにアルゴリズム2つ選定した結果

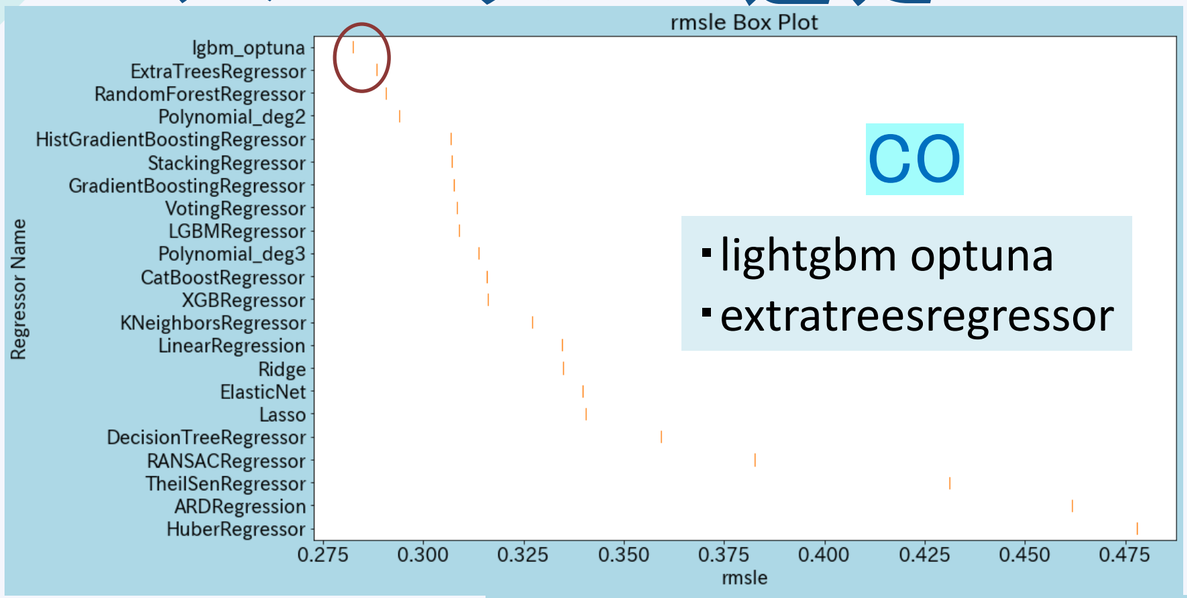

CO

- lightgbm optuna
- extratreesregressor

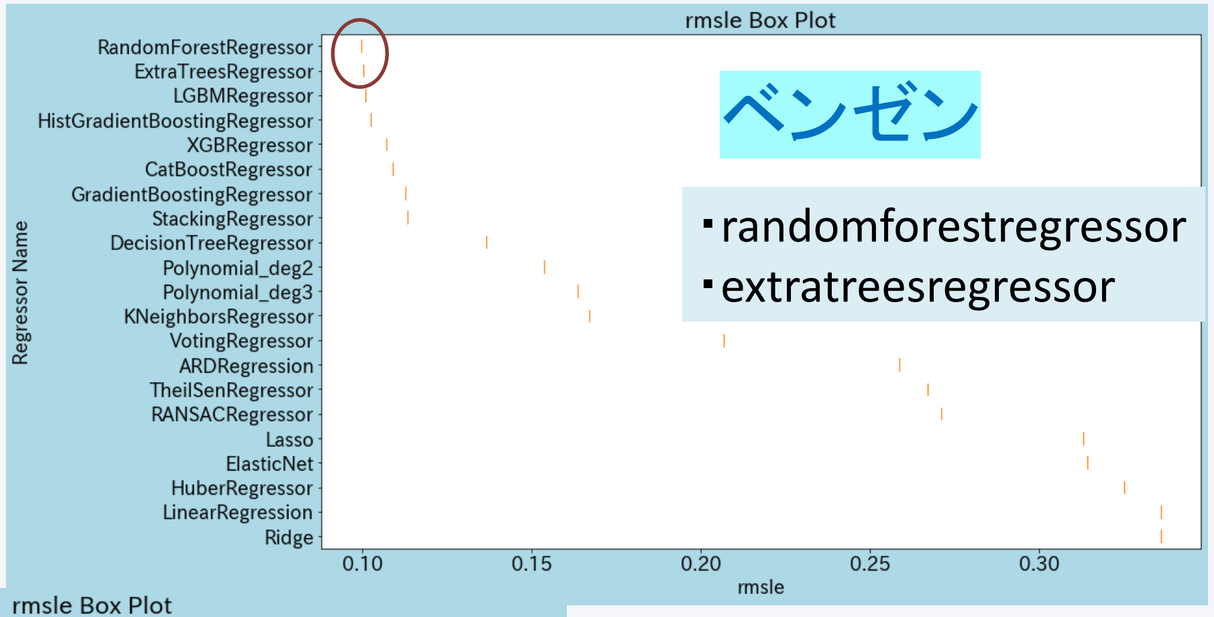

ベンゼン

- randomforestregressor
- extratreesregressor

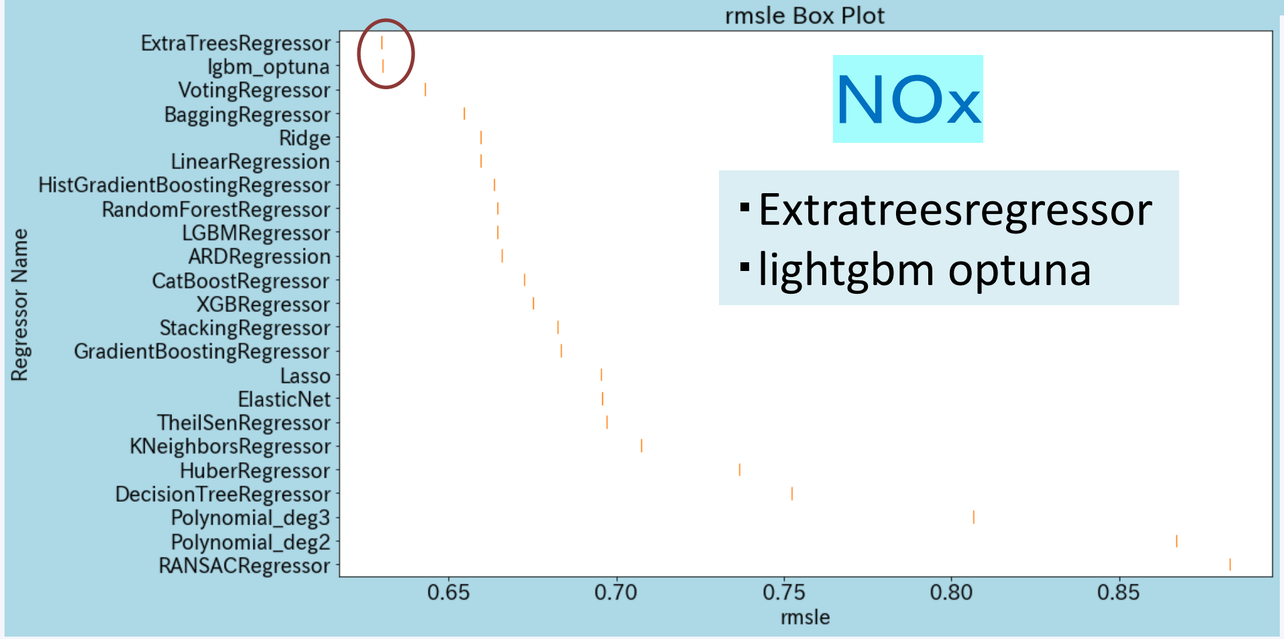

NOx

- Extratreesregressor
- lightgbm optuna

モデル開発

② CO,Nox,ベンゼンと予測値のアルゴリズムで相性確認

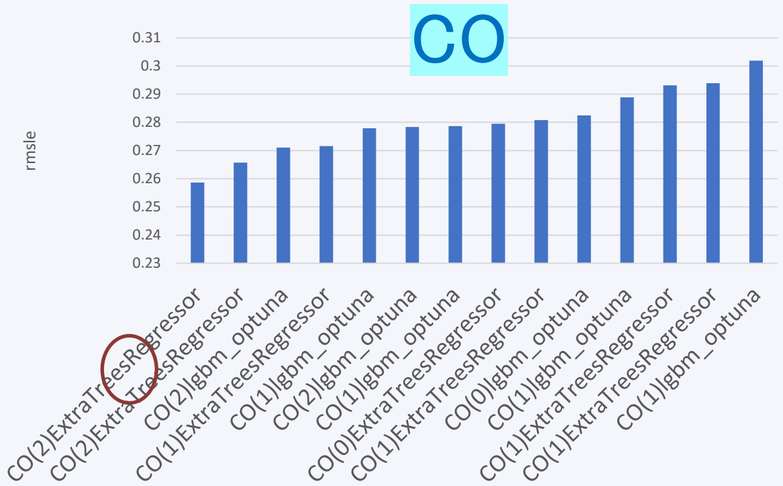

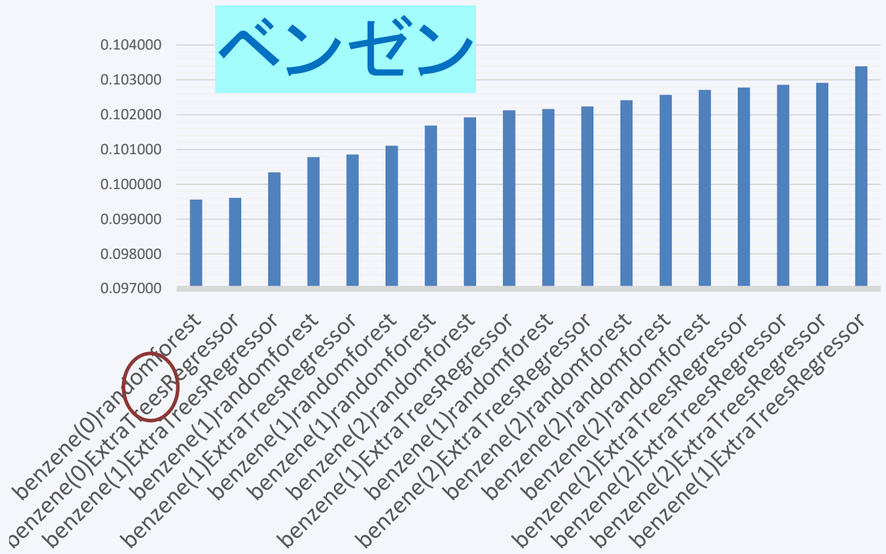

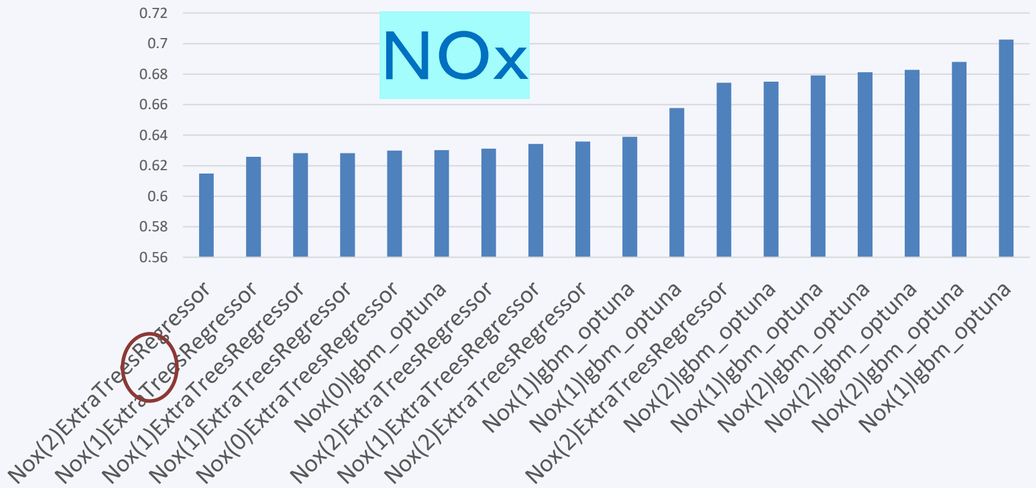

使用したモデルと予測値の構成

NOx

CO(予測値2)
(Lightgbm optuna)

ベンゼン(予測値1)
(randomforest)

Model:
Extratrees
regressor

Parameter:
n_estimators=100,bootstrap = True,
random_state = 0

精度:
Rmsle:0.068
R2:0.988

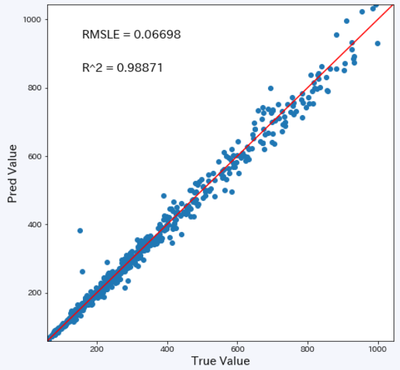

CO

NOx(予測値2)
(lightgbm optuna)

ベンゼン(予測値1)
(extratreesregressor)

Model:
Extratrees
regressor

Parameter:
n_estimators=100,bootstrap = True,
random_state = 0

精度:
Rmsle:0.065
R2:0.958

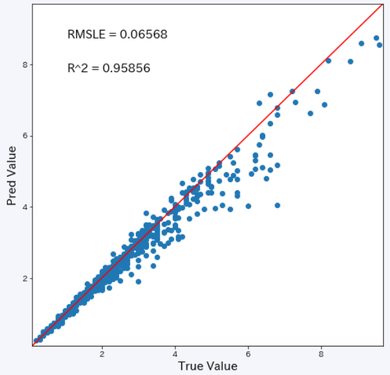

ベンゼン

単独

Model:
Randomforest
regressor

Parameter:
random_state = 0

精度:
Rmsle:0.101
R2:0.970

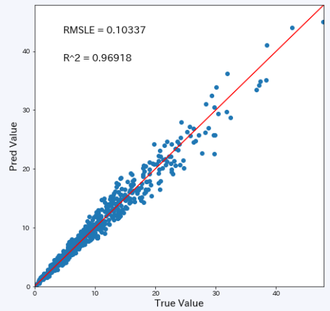

V

外れ値処理

箱ひげ図

目視で範囲指定し特定

absolute_humidity
2010/9/12 16:00　2.231

sensor_1
2010/10/26 18:00　2022.5
2010/11/23 18:00　2021.6
2010/11/23 19:00　2088.3

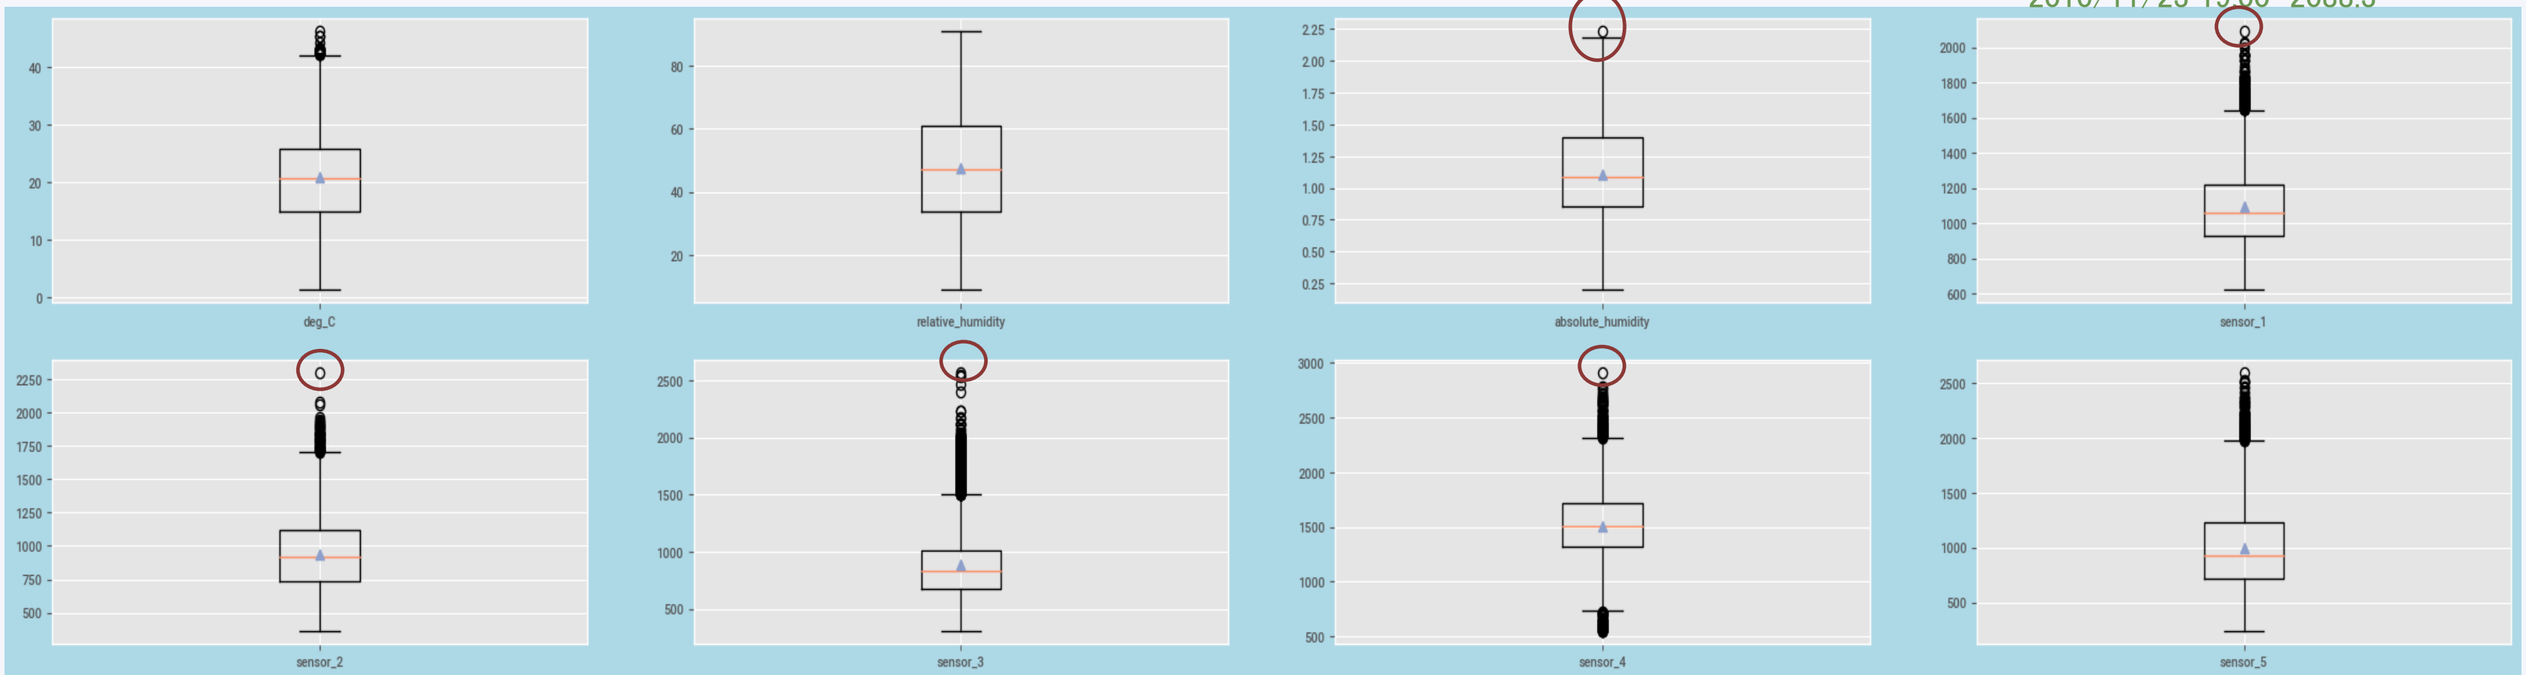

sensor_2
2010/11/22 10:00　2302.6

sensor_3
2010/12/10 5:00　2533.4
2010/12/10 7:00　2548.8
2010/12/10 10:00　2567.4

sensor_4
2010/10/26 18:00　2913.8

VI

異常値処理

折れ線グラフ

目視による異常値特定を実施
○箇所の行削除を実施

○ :除去して精度向上につながった個所

⊗ :除去して精度向上につながらなかった個所

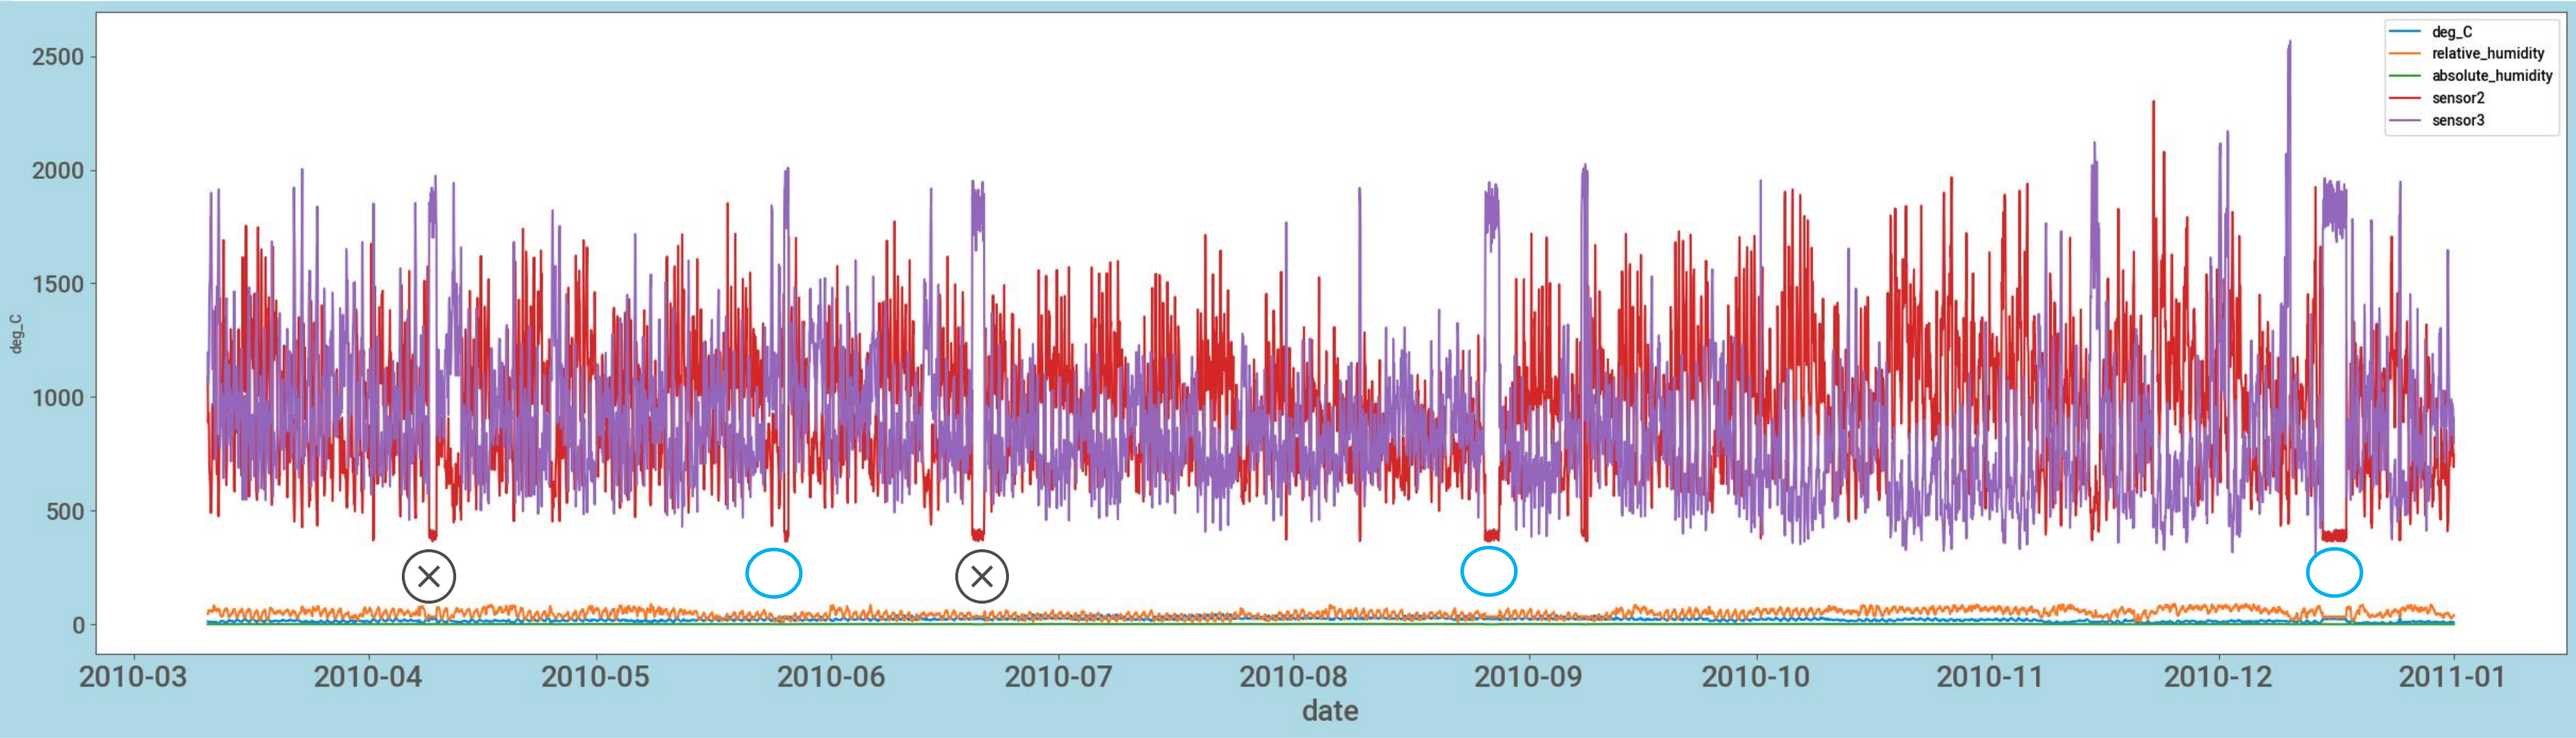

※Sensor_4は合わせると
全体が見にくくなるため
載せていません。

VII

特 徴 量 作 成

活用した特徴量

元データ
✓気温
✓絶対湿度
✓相対湿度
✓センサー1
✓センサー2
✓センサー3
✓センサー4
✓センサー5
✓ベンゼン
✓CO
✓NOx

加工データ(目的変数、気温、湿度を使用)
✓ラグ特徴量(shift1,shift2)
✓ローリング特徴量(rolling(3).min())
✓ローリング特徴量(rolling(3).max())
✓ローリング特徴量(rolling(240).min())
✓ローリング特徴量(rolling(240).max())
✓単純移動平均(rolling(3).mean())
✓単純移動平均(rolling(240).mean())
✓加重移動平均(rolling(3).apply(calc_wma))
✓加重移動平均(rolling(240).apply(calc_wma))
✓指数移動平均(ewm(span=3,adjust=False).mean())
✓指数移動平均(ewm(span=240,adjust=False).mean())

※COのみ
✓ローリング特徴量(最大値−最小値)

特徴量の貢献度

CO

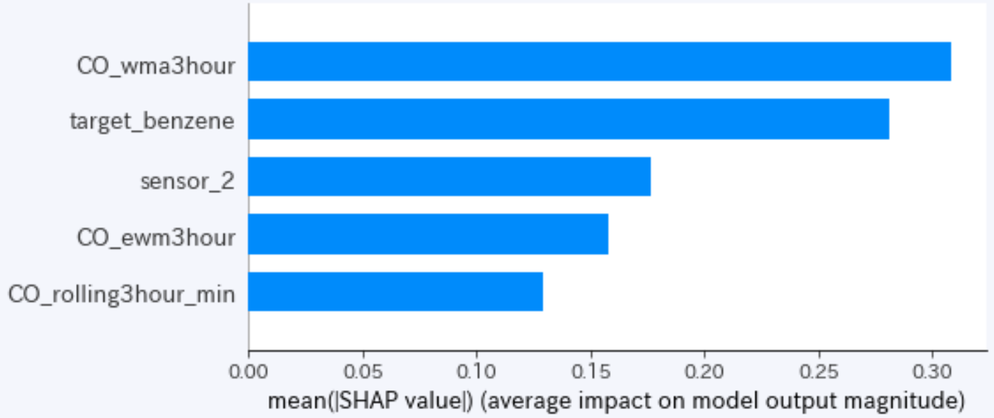

ベンゼン

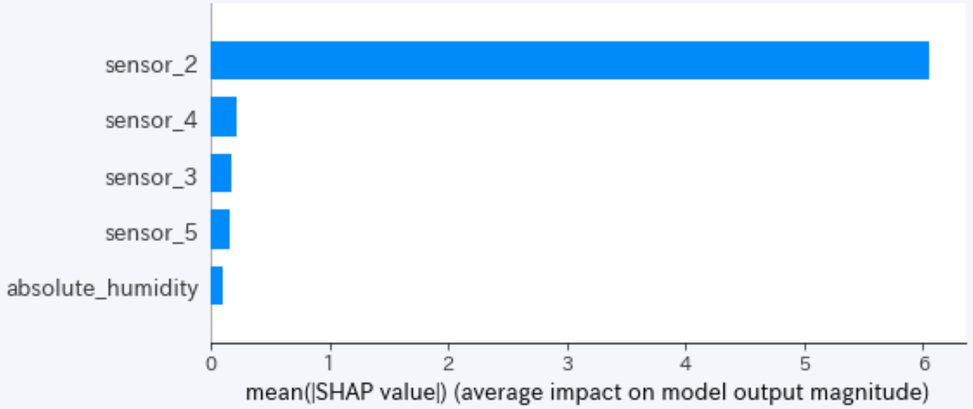

NOx

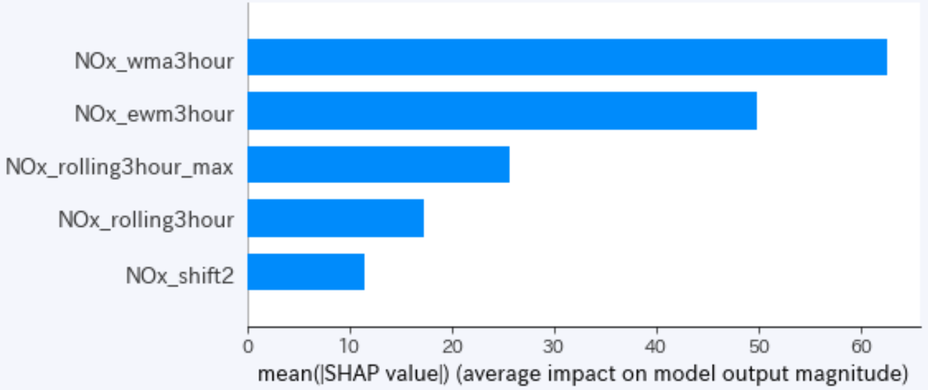

やったけどうまく活用できなかったこと

- ✓時間に関する特徴量(年、月、日、時、曜日、朝昼夜の3分割など)
- ✓飽和水蒸気量(=相対湿度/絶対湿度/100)の特徴量
- ✓10分割区分(温度、湿度、センサーデータ)の特徴量
- ✓次元削減(PCA,t-SNE,UMAP)
- ✓トレンド加味

VIII

バリデーション

訓練期間と検証期間の変更による精度確認

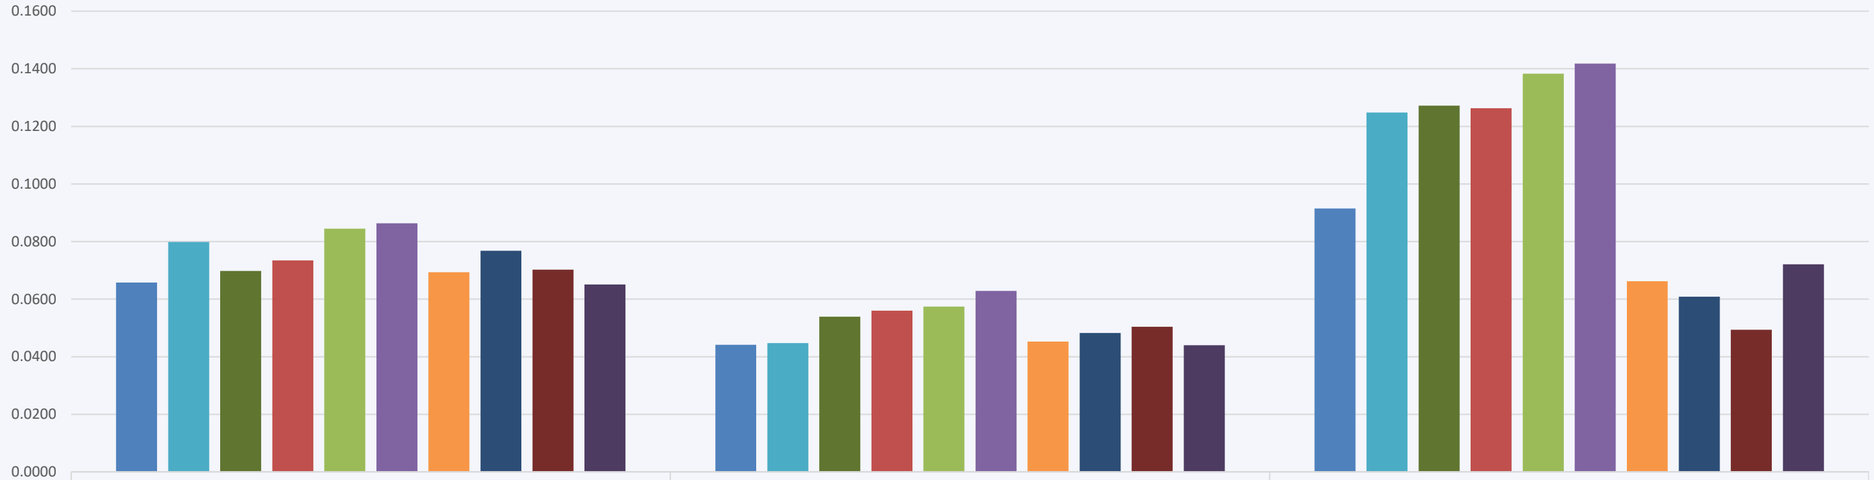

	CO	ベンゼン	Nox
訓練:検証(9:1)	0.0658	0.0442	0.0915
訓練:検証(8:2)	0.0799	0.0448	0.1248
訓練:検証(7:3)	0.0698	0.0539	0.1272
訓練:検証(6:3)	0.0734	0.0560	0.1263
訓練:検証(5:3)	0.0845	0.0574	0.1383
訓練:検証(4:3)	0.0864	0.0629	0.1418
検証期間3週間(12/10-)	0.0694	0.0452	0.0662
検証期間2週間(12/17-)	0.0768	0.0483	0.0608
検証期間1週間(12/24-)	0.0702	0.0504	0.0494
検証期間5週間(11/24-)	0.0651	0.0440	0.0721

IX

まとめ

精度結果

Kaggle private score:0.21611(770/1293)
public score:0.24969(558/1293)

Rmsle:0.065
R2:0.958

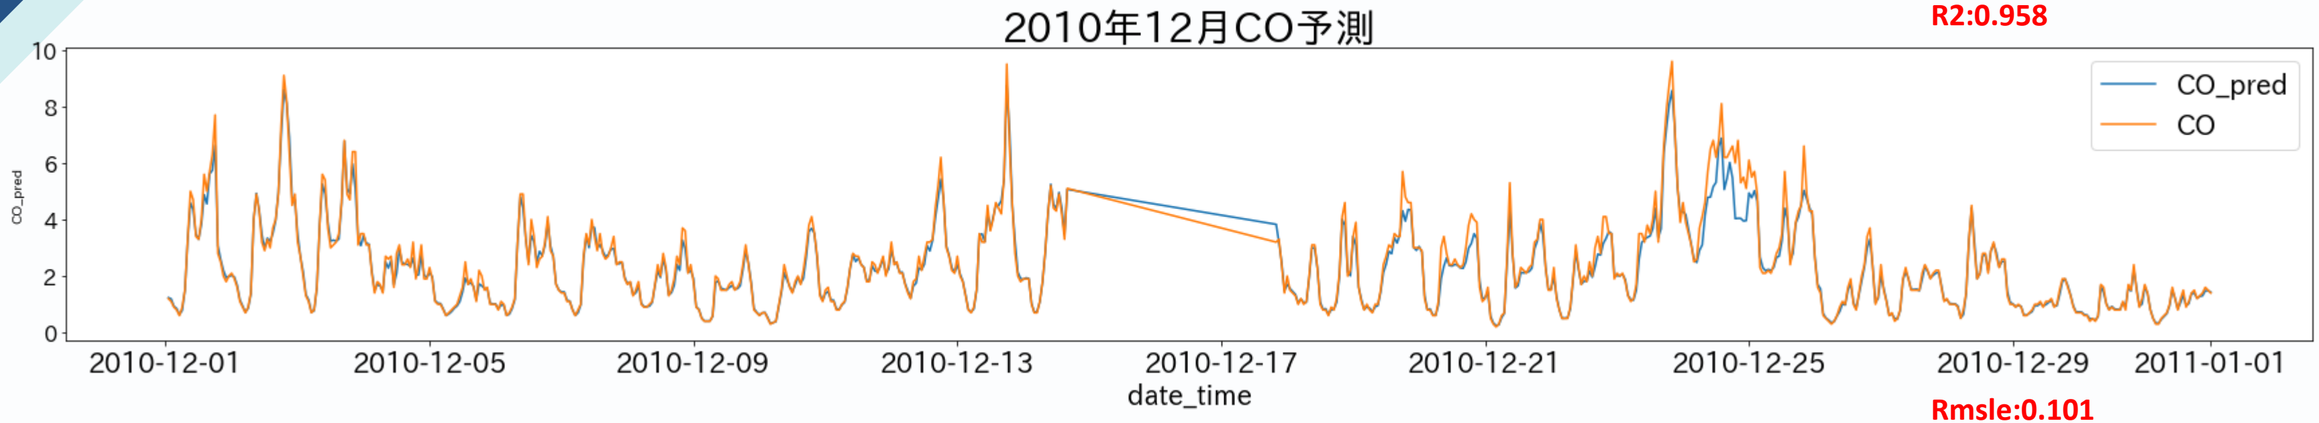

Rmsle:0.101
R2:0.970

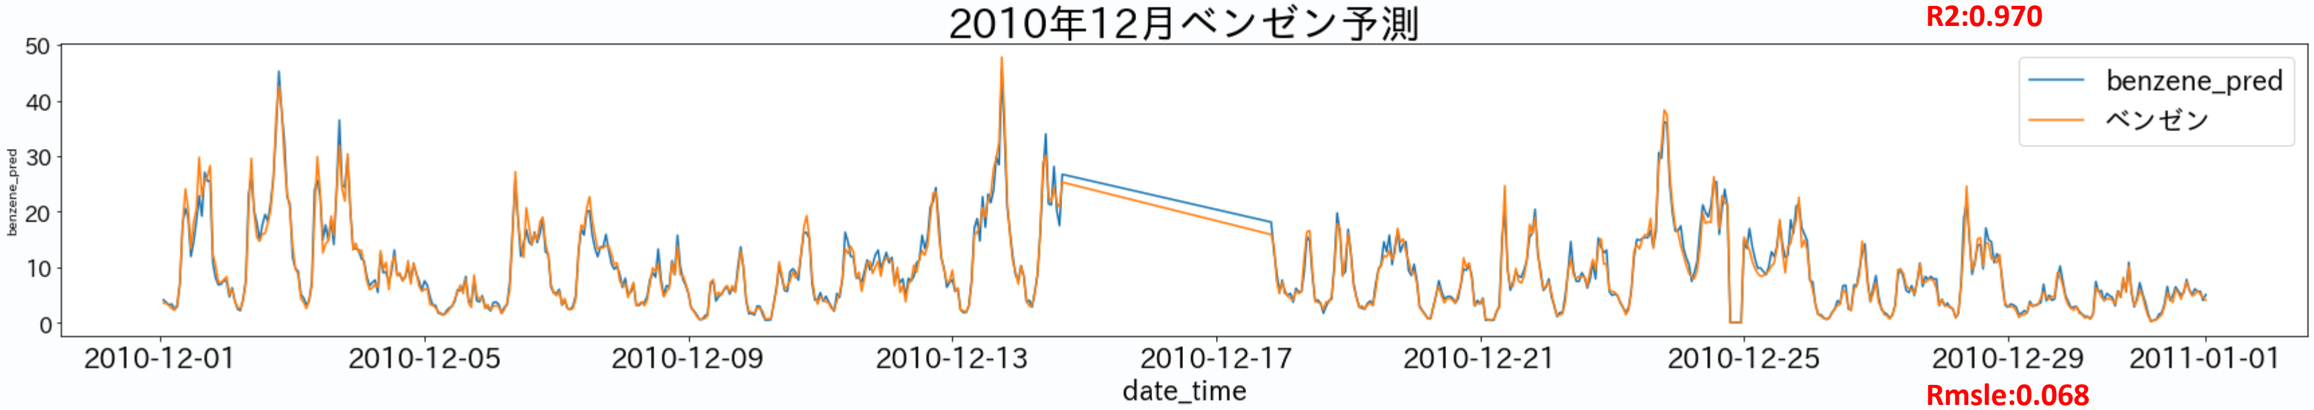

Rmsle:0.068
R2:0.988

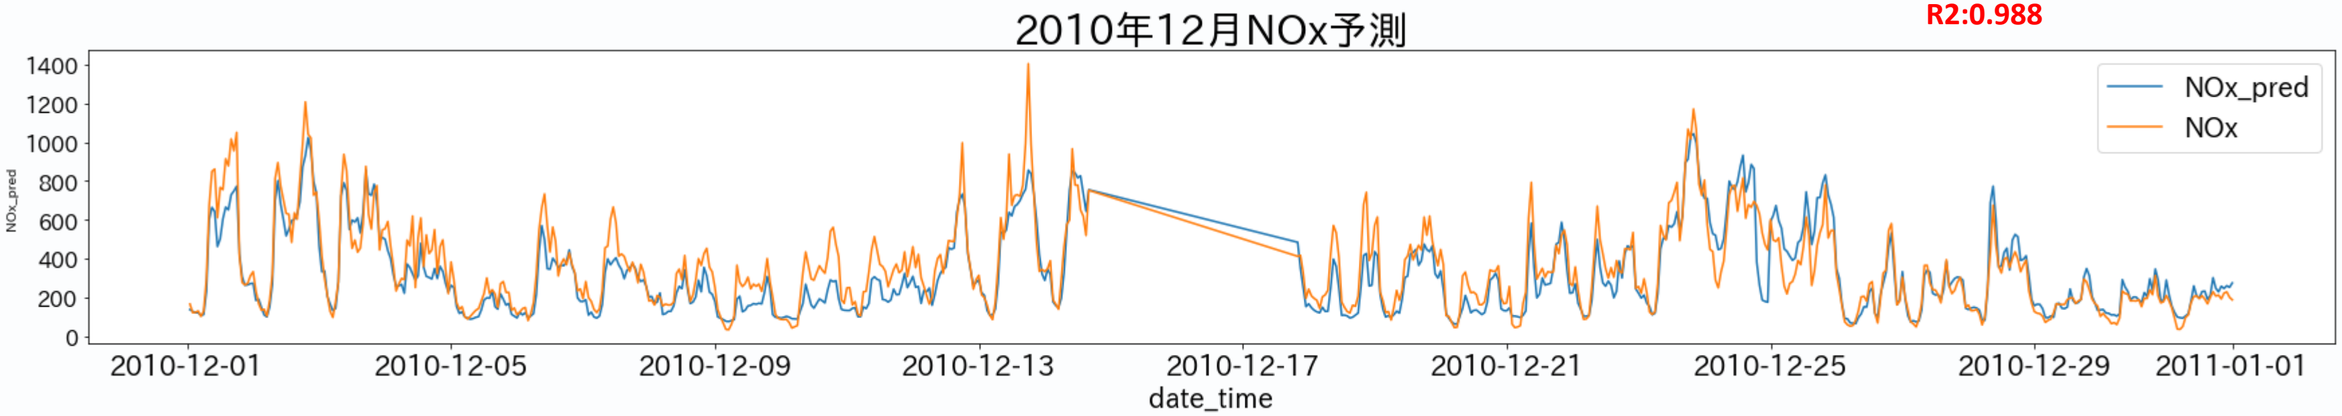

ここまででわかったこと

✓目的変数同士が、正の相関があり、COやNOxは他の目的変数の予測値を説明変数として取り入れることで、精度向上に繋がる

✓目的変数ごとに、検証期間の長さを変更することによって精度に違いがある

✓3つの目的変数を予測ごとに、予測段階ごとに、各オリジナルのモデル構築、特徴量を取り入れることで精度向上に繋がった

以上のことがわかりました

難しかった点

✓時間に関する特徴量(時、年、月、日、曜日、朝昼夜の3分割など)が時系列データなのに効かなかった。

✓元データの特徴量が少ない。

→風量や風速がなかった。これらの特徴量は、精度向上に繋がると感じた。

✓人工的に作られたデータである。

→科学技術論文通りにいかないこともあるのではないかと考えた。また、地域性もわからないから仮説が難しかった。

✓ベンゼンの精度向上につながる特徴量を作成できなかった。

→最後、予測値1,2を正解値で推論していたことに気付き、精度確認を行いなおしたため、効果がある特徴量を時間内に見つけきれませんでした。

■ただし、3つの目的変数の予測精度向上のために、仮説を検証し様々な施策を行うことが出来ました。
焦りましたが、最後まで粘ってよかったです。

ご清聴ありがとうございます

NeuroDiveFukuoka　小林稔征